

# Network Science

dataScience UDD



A large, semi-transparent network graph is centered in the background. It consists of numerous small, glowing blue dots representing nodes, connected by a web of thin white lines representing edges. The graph has a organic, branching structure, with a denser cluster of nodes at the bottom left and more scattered connections towards the top right.

## Cristian Candia-Castro Vallejos, Ph.D.

[cristiancandia@udd.cl](mailto:cristiancandia@udd.cl)

Director Magister en Data Science UDD

Profesor Investigador, Facultad de Ingeniería, UDD

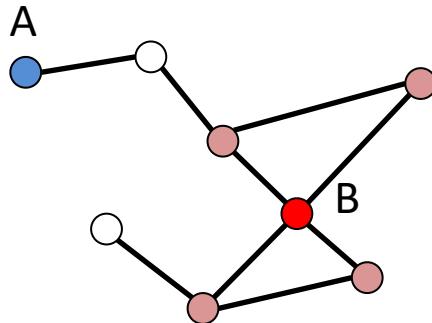
External Faculty Northwestern Institute on Complex Systems,  
Kellogg School of Management, Northwestern University

# Modelos de Formación de Redes

Estas diapositivas se basan en la presentación original del  
Prof. Albert-László Barabási, de Northeastern University, con autorización.  
El contenido ha sido traducido para su uso en este curso.

# Distribución de grado

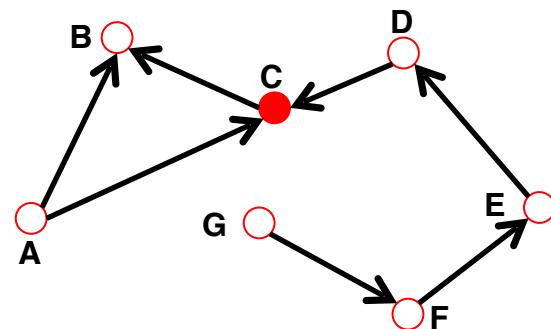
## No-dirigido



Grado del nodo: el número de links conectados al nodo.

$$k_A = 1 \quad k_B = 4$$

## Dirigido



En **redes dirigidas** Podemos definir un grado de entrada (in-degree) y un grado de salida (out-degree). El grado total es la suma de ambos.

$$k_C^{in} = 2 \quad k_C^{out} = 1 \quad k_C = 3$$

Fuente: un nodo con  $k^{in}=0$ ; Sumidero: un nodo con  $k^{out}=0$ .

# Estadística

## Breve revisión estadística

Four key quantities characterize a sample of  $N$  values  $x_1, \dots, x_N$ :

### Promedio:

$$\langle x \rangle = \frac{x_1 + x_2 + \dots + x_N}{N} = \frac{1}{N} \sum_{i=1}^N x_i$$

### El $n$ -esimo momento:

$$\langle x^n \rangle = \frac{x_1^n + x_2^n + \dots + x_N^n}{N} = \frac{1}{N} \sum_{i=1}^N x_i^n$$

## Desviación estándar

$$\sigma_x = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \langle x \rangle)^2}$$

## Distribución de $x$

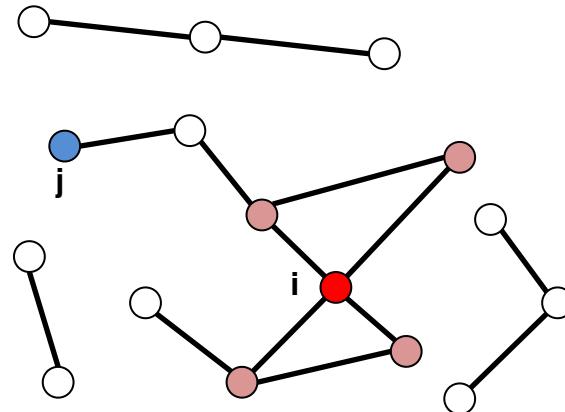
$$p_x = \frac{1}{N} \sum_i \delta_{x, x_i}$$

## Donde $x$ sigue: §

$$\sum_i p_x = 1 \left( \int p_x dx = 1 \right)$$

## Grado promedio

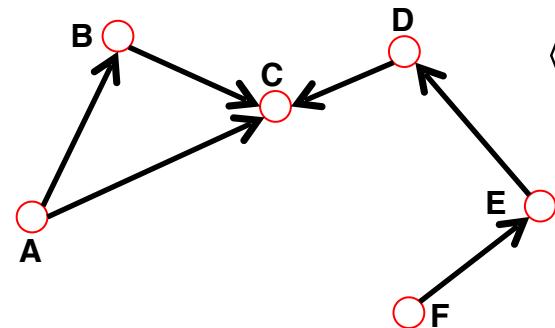
No-dirigido



$$\langle k \rangle \equiv \frac{1}{N} \sum_{i=1}^N k_i \quad \langle k \rangle = \frac{2L}{N}$$

N – el número de nodos en el grafo

Dirigido



$$\langle k^{in} \rangle \equiv \frac{1}{N} \sum_{i=1}^N k_i^{in}, \quad \langle k^{out} \rangle \equiv \frac{1}{N} \sum_{i=1}^N k_i^{out}, \quad \langle k^{in} \rangle = \langle k^{out} \rangle$$

$$\langle k \rangle \equiv \frac{L}{N}$$

# Grado promedio

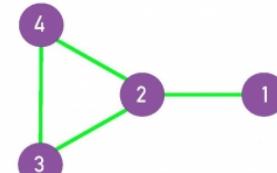
NETWORK	NODES	LINKS	DIRECTED UNDIRECTED	N	L	$\langle k \rangle$
Internet	Routers	Internet connections	Undirected	192,244	609,066	6.33
WWW	Webpages	Links	Directed	325,729	1,497,134	4.60
Power Grid	Power plants, transformers	Cables	Undirected	4,941	6,594	2.67
Mobile Phone Calls	Subscribers	Calls	Directed	36,595	91,826	2.51
Email	Email addresses	Emails	Directed	57,194	103,731	1.81
Science Collaboration	Scientists	Co-authorship	Undirected	23,133	93,439	8.08
Actor Network	Actors	Co-acting	Undirected	702,388	29,397,908	83.71
Citation Network	Paper	Citations	Directed	449,673	4,689,479	10.43
E. Coli Metabolism	Metabolites	Chemical reactions	Directed	1,039	5,802	5.58
Protein Interactions	Proteins	Binding interactions	Undirected	2,018	2,930	2.90

# Distribución de grado

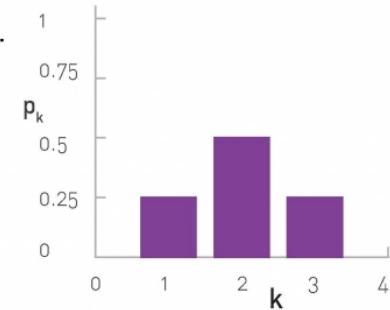
## Distribución de grado

$P(k)$ : probabilidad de que un nodo elegido aleatoriamente tenga grado  $k$

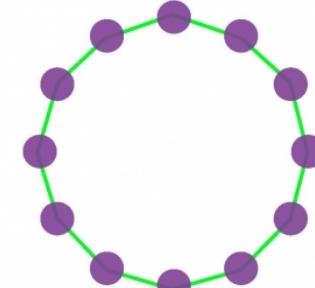
a.



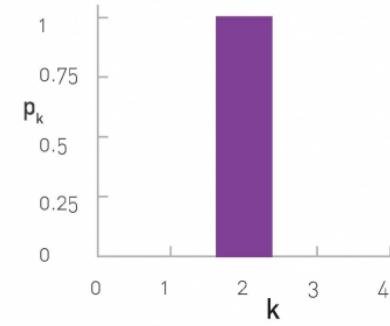
b.



c.



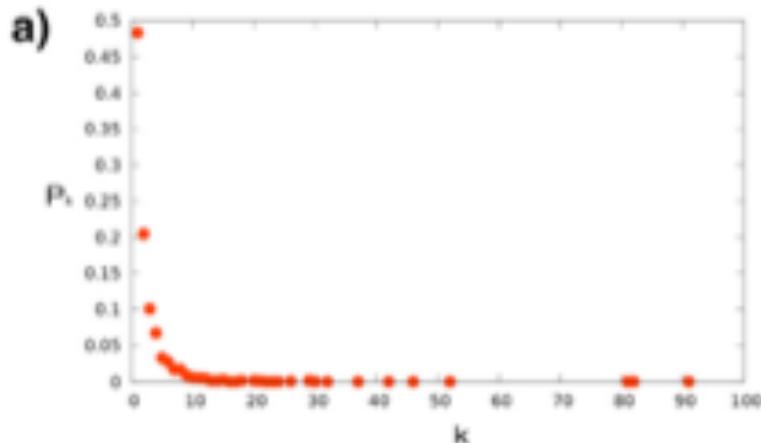
d.



$N_k = \# \text{ nodos con grado } k$

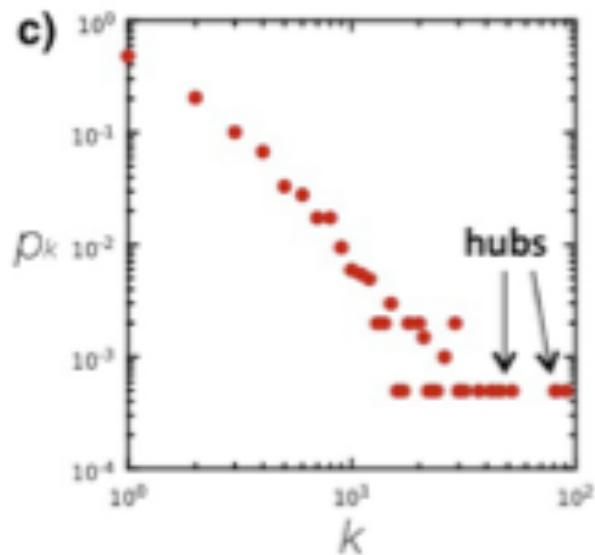
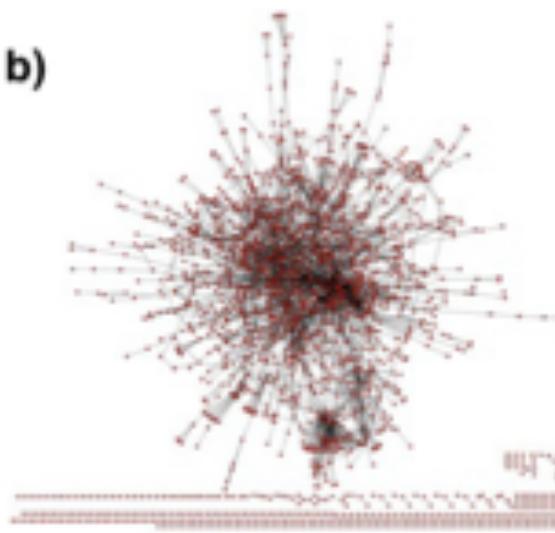
$P(k) = N_k / N \rightarrow \text{plot}$

# Distribución de grado



En muchas redes reales, el grado de nodo puede variar considerablemente. Por ejemplo, como indica la distribución de grados (a), los grados de las proteínas en la red de interacción de proteínas que se muestran en (b) varían entre  $k = 0$  (nodos aislados) y  $k = 92$ , que es el grado del nodo más grande, llamado un centro. También hay grandes diferencias en el número de nodos con diferentes grados: como muestra (a), casi la mitad de los nodos tienen grado uno (es decir,  $p_1 = 0.48$ ), mientras que solo hay una copia del nodo más grande, por lo tanto,  $p_{92} = 1 / N = 0.0005$ . (c) La distribución de grados a menudo se muestra en el llamado gráfico log-log, en el que trazamos  $\log p_k$  en función de  $\log k$ , o, como hicimos en (c), usamos ejes logarítmicos.

b)



# DISTRIBUCION DE GRADO

**Representación discreta:**  $p_k$  Es la probabilidad de que un nodo tenga grado  $k$ .

**Descripción continua:**  $p(k)$  es la pdf de los grados, donde

$$\int_{k_1}^{k_2} p(k) dk$$

representa la probabilidad de que el grado de un nodo esté entre  $k_1$  y  $k_2$ .

**Condición de normalización:**

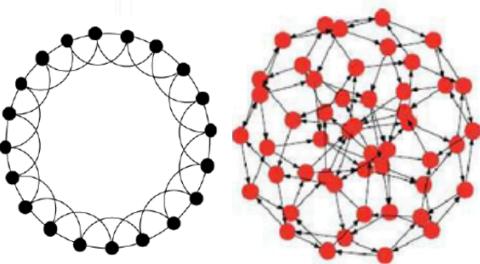
$$\sum_0^{\infty} p_k = 1$$

$$\int_{K_{\min}}^{\infty} p(k) dk = 1$$

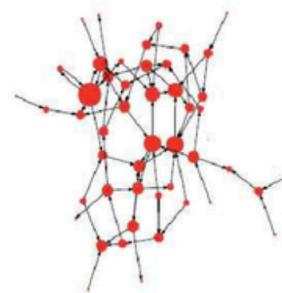
donde  $K_{\min}$  es el mínimo grado de la red.

# Distribución de grado

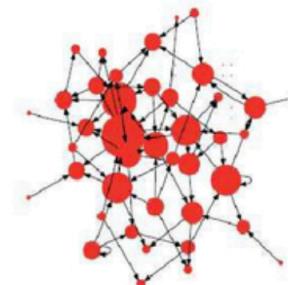
**Regular**



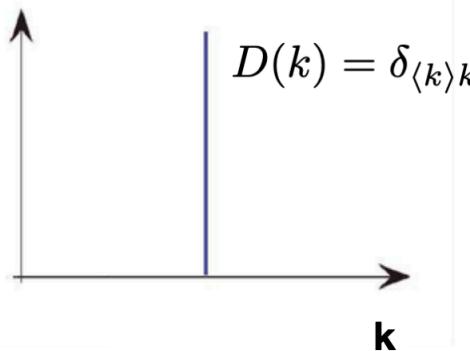
**Random**



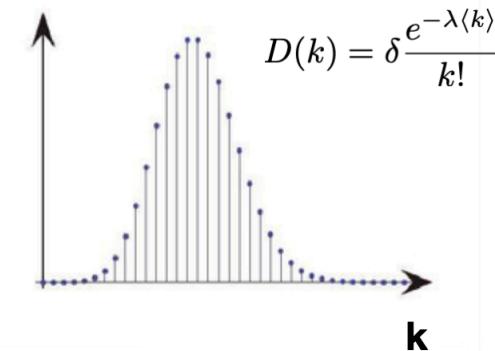
**Scale Free**



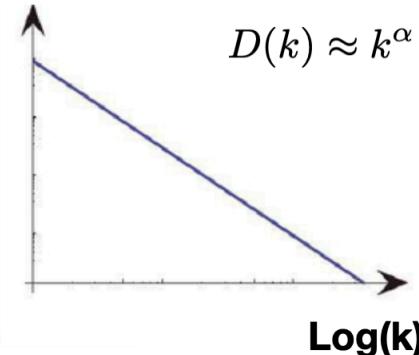
$D(k)$



$D(k)$

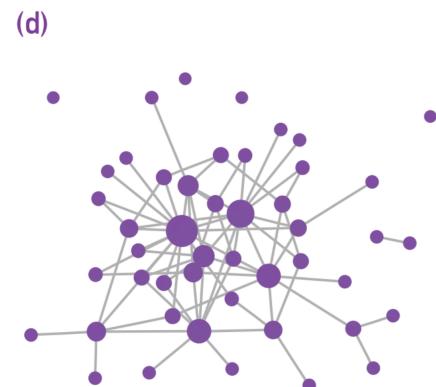
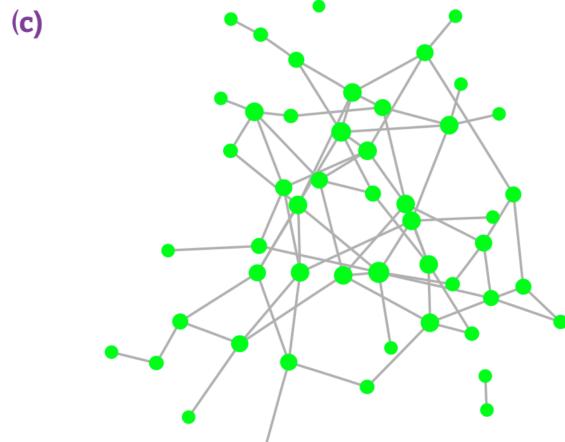
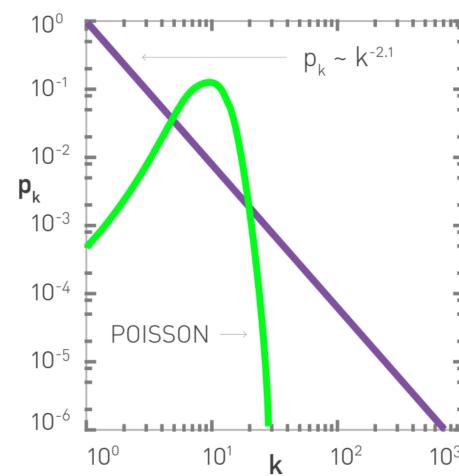
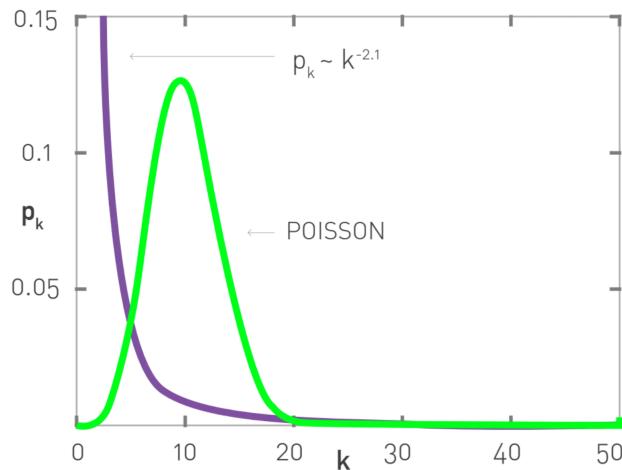


$\text{Log}(D(k))$



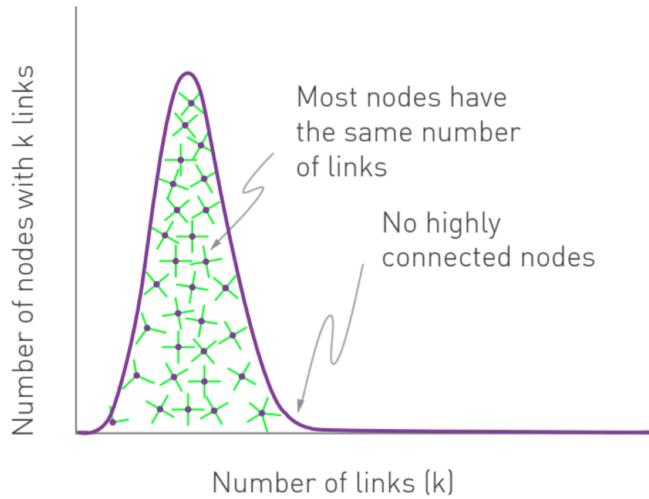
Piensen en los histogramas de fercuencias de grado  
¿Cómo se comparan los promedios con los valores máximos?

# Diferencia entre red aleatoria y libre de escala

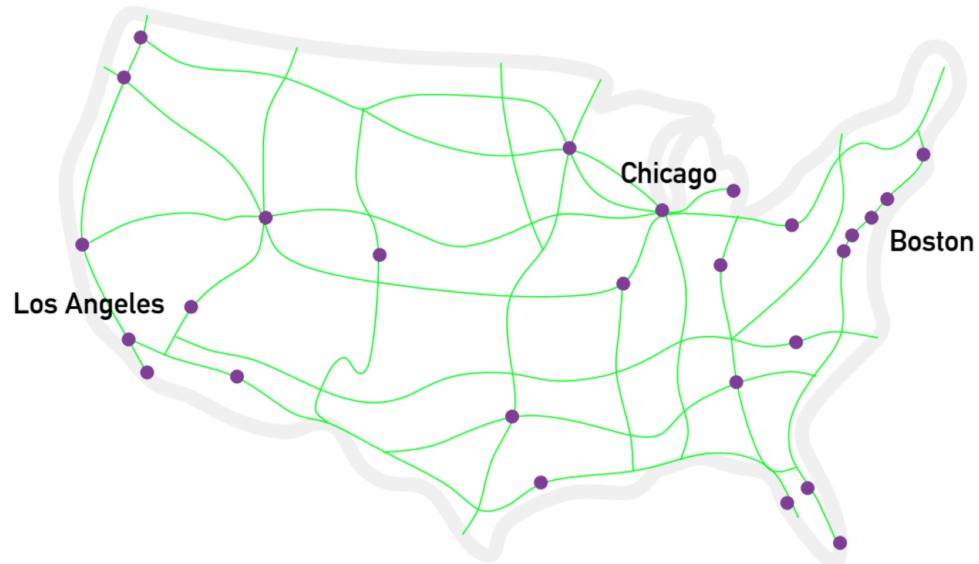


# Diferencia entre red aleatoria y libre de escala

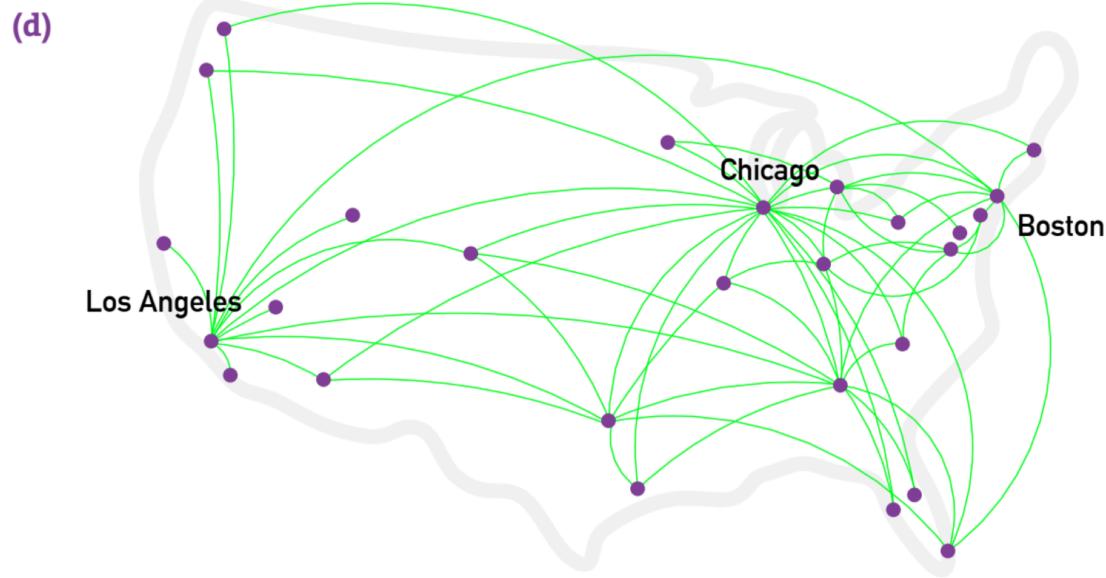
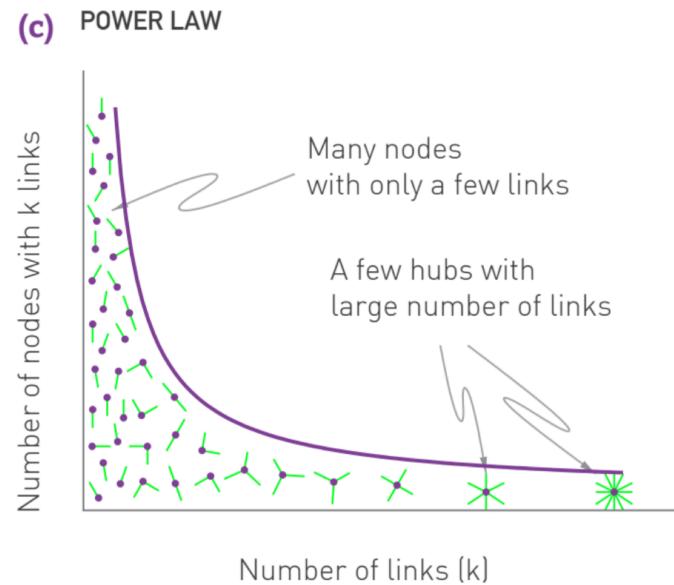
(a) POISSON



(b)

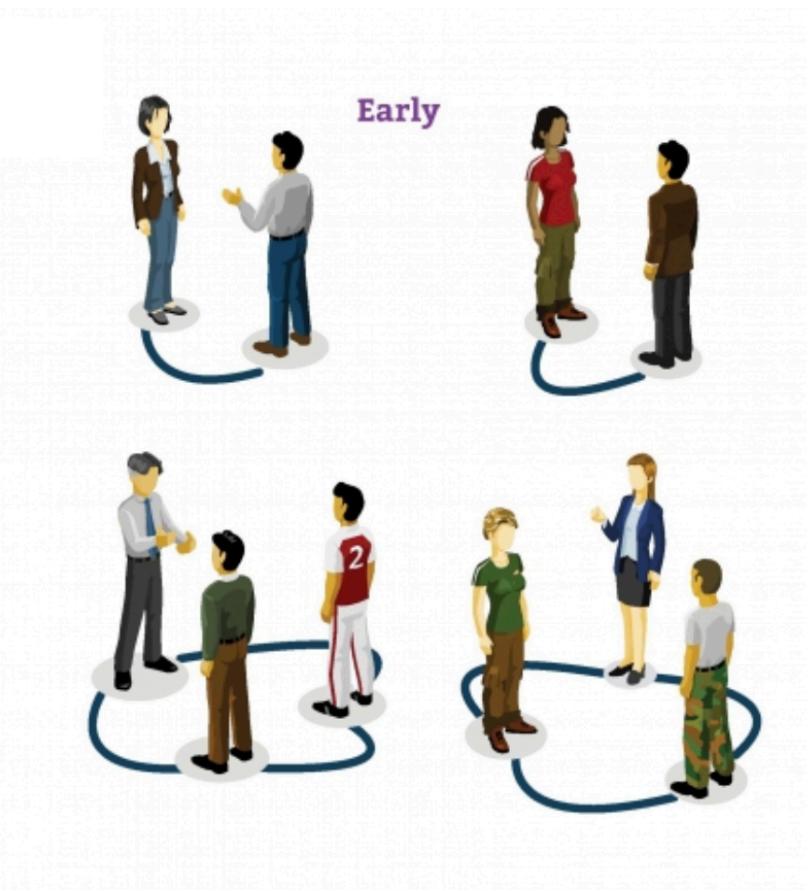


# Diferencia entre red aleatoria y libre de escala

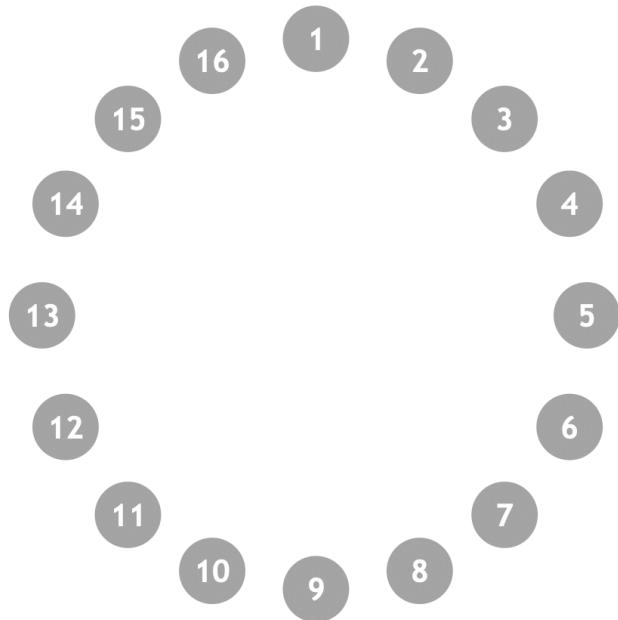


Estas estructuras tienen un impacto significativo en cómo se propaga la información en los sistemas físicos, biológicos, sociales, etc.

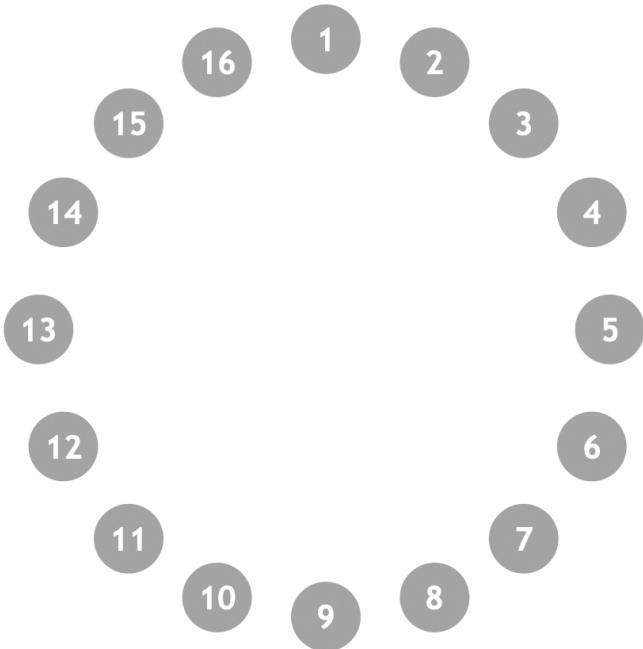
# MODELO DE REDES ALEATORIAS



# the party algorithm

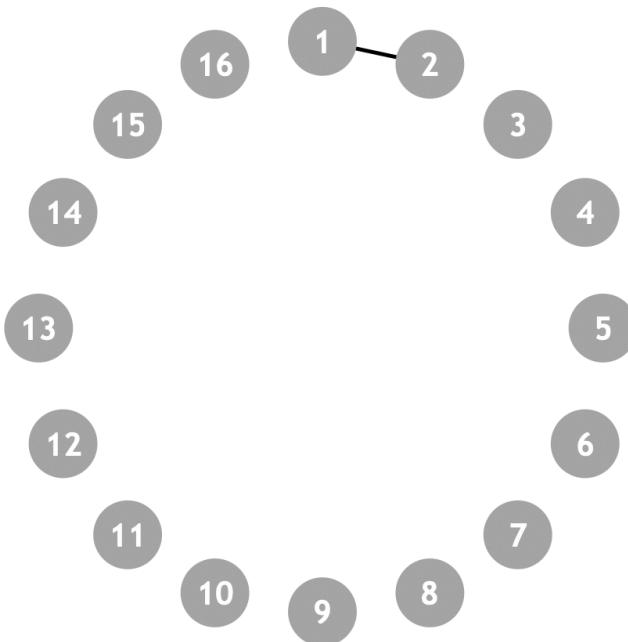


# the party algorithm



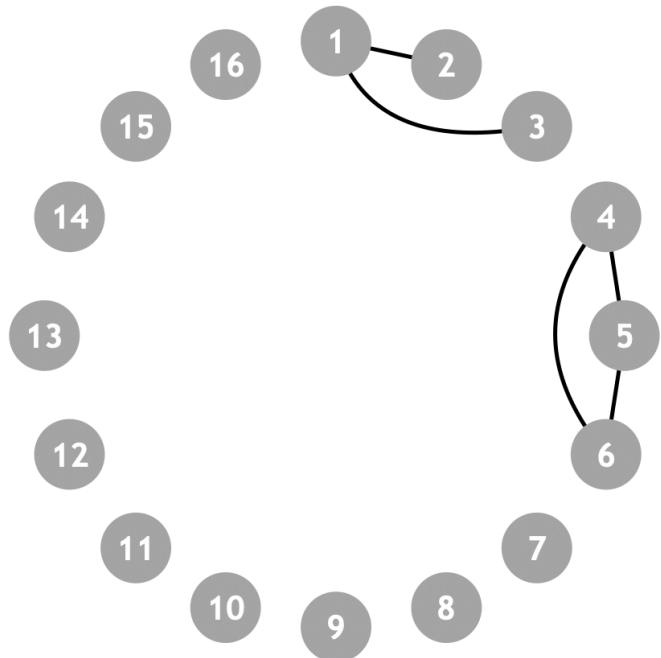
Hagamos un seguimiento de quién habla con quién

# the party algorithm



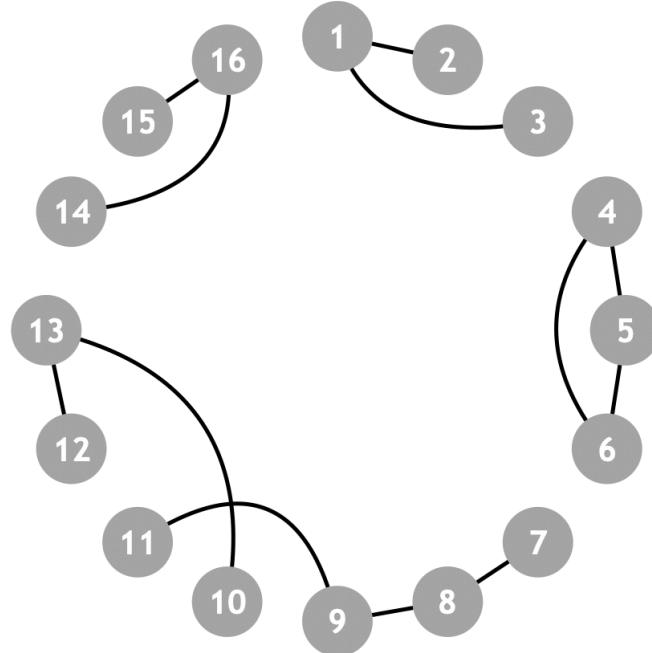
Hagamos un seguimiento de quién habla con quién

# the party algorithm



Hagamos un seguimiento de quién habla con quién

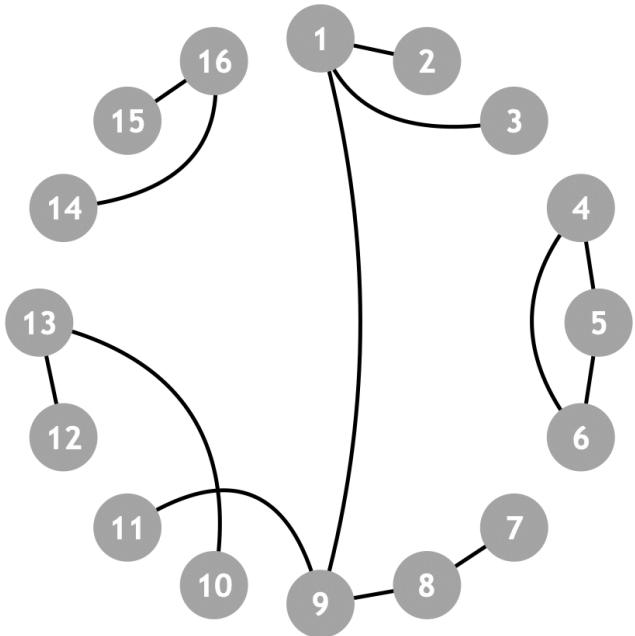
# the party algorithm



Hagamos un seguimiento de quién habla con quién

Al principio, la gente habla principalmente con otros que están sentados cerca.

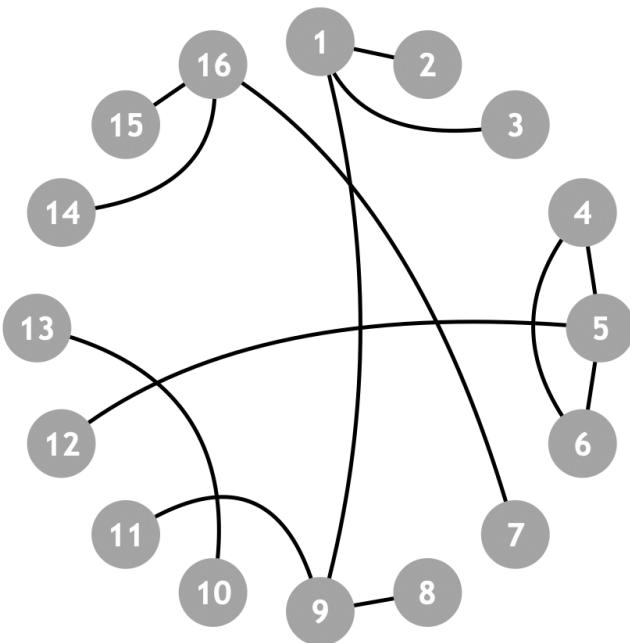
# the party algorithm



Hagamos un seguimiento de quién habla con quién

Sin embargo, como la cena avanza hacia las bebidas nocturnas y los invitados se ponen de pie, vemos la reorganización de sus relaciones y se forman nuevos vínculos

# the party algorithm

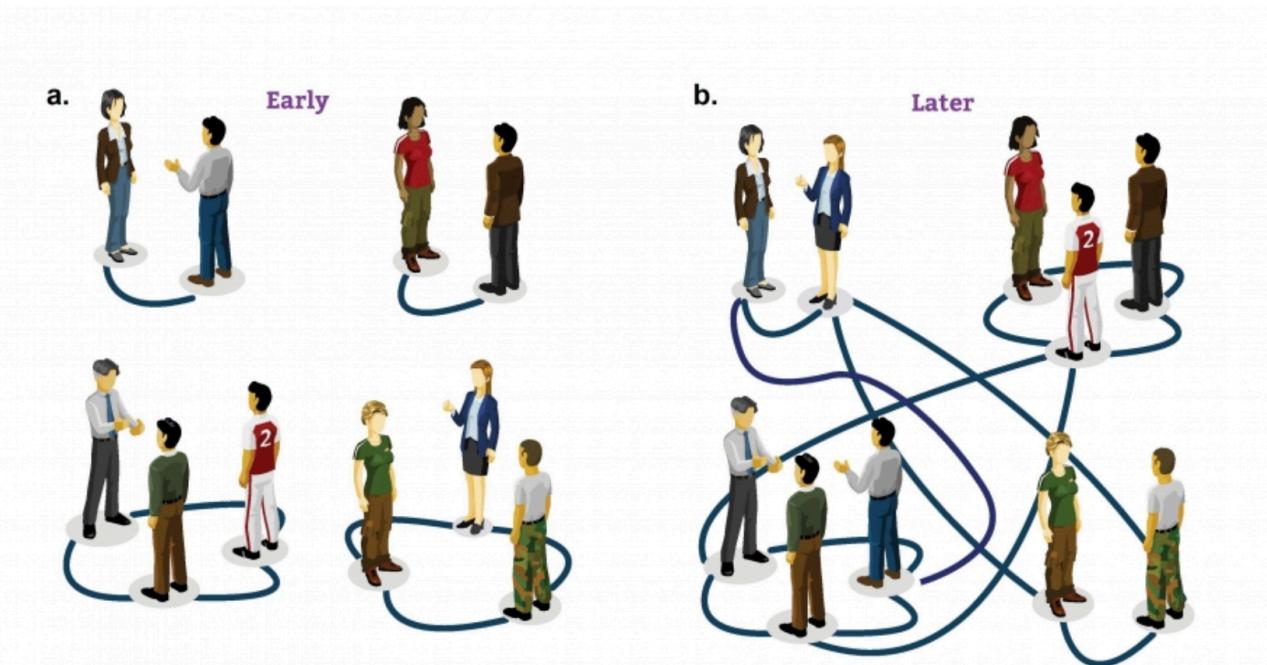


Estas redes no siguen ninguna regla física como en los ejemplos anteriores.

En cambio, son algo aleatorias.  
¿No te parece?

Pregunta: ¿Podemos construir un modelo que intente capturar las propiedades de estas redes?

# Un algoritmo simple para redes sociales

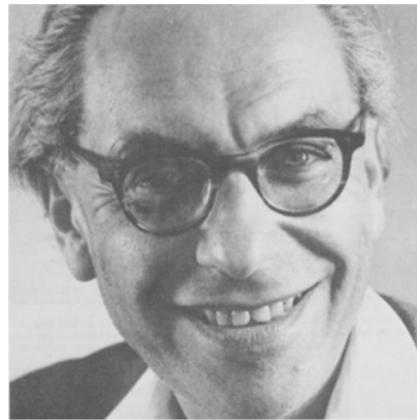


Invitados a una cena se reunen al azar y establecen relaciones sociales.

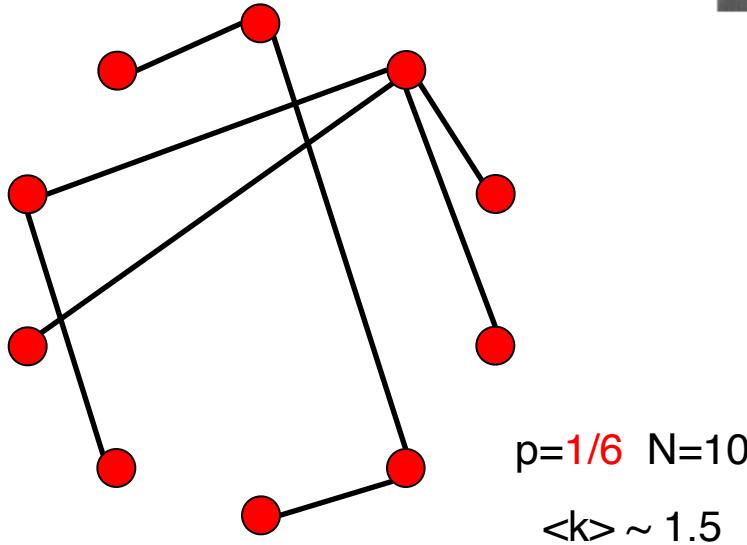
# El modelo de redes aleatorias

# MODELO DE REDES ALEATORIAS

Pául Erdös  
(1913-1996)



Alfréd Rényi  
(1921-1970)

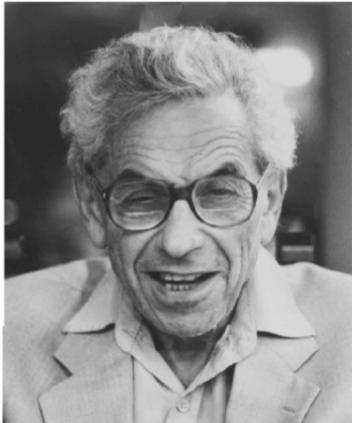


Erdős-Rényi model (1960)

Un **gafo aleatorio** es un grafo de  $N$  nodos donde cada par de nodos está conectado con una probabilidad  $p$ .

# Random Networks

a.

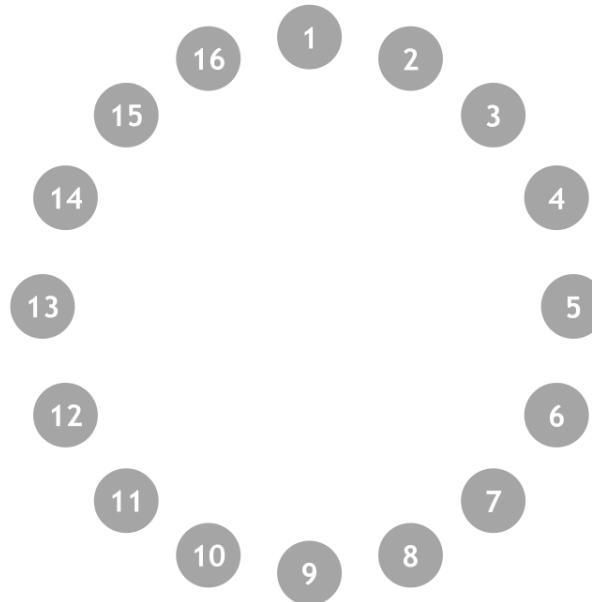


Pál Erdős

b.



Alfréd Rényi



## Erdős-Rényi algorithm

**condición inicial** Comenzando con  $N$  nodos desconectados ( $L = 0$  enlaces)

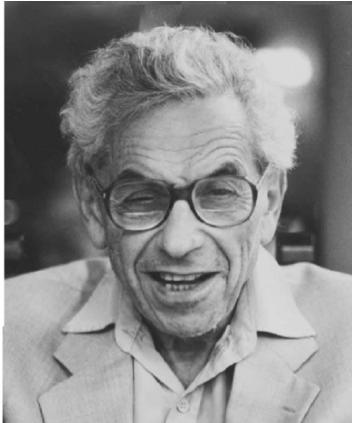
**paso iterativo** Para cada par de individuos, establezca un vínculo con probabilidad  $p$

# Random Networks

Conectar 1 con 2?

is Random() < p

a.

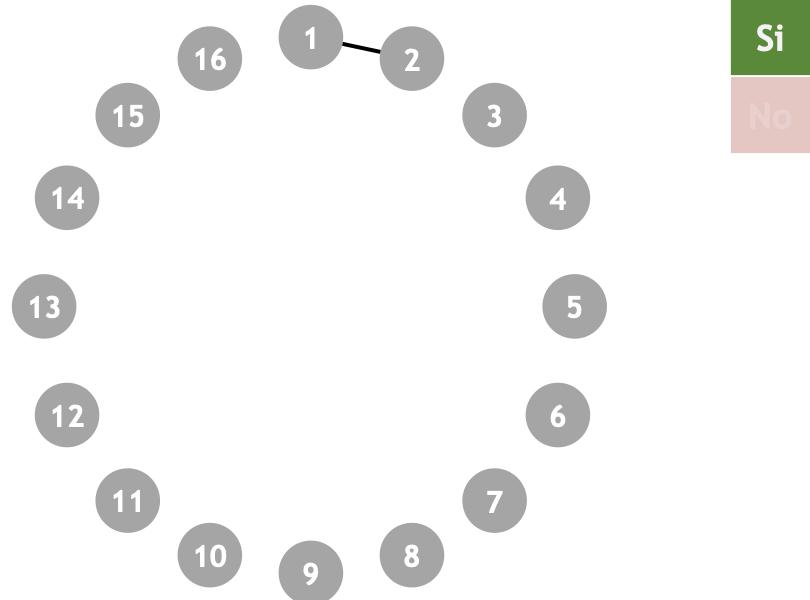


Pál Erdős

b.



Alfréd Rényi



## Erdős-Rényi algorithm

**condición inicial** Comenzando con N nodos desconectados ( $L = 0$  enlaces)

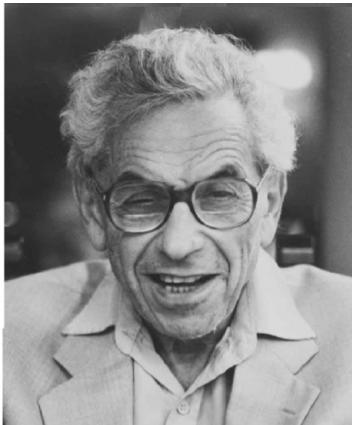
**paso iterativo** Para cada par de individuos, establezca un vínculo con probabilidad  $p$

# Random Networks

Conecitar 1 con 3?

is Random() < p

a.

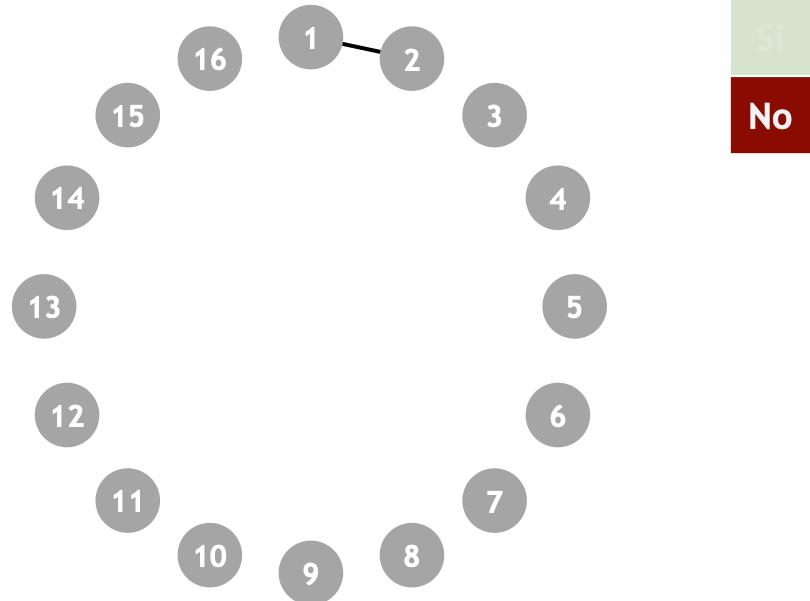


Pál Erdős

b.



Alfréd Rényi



## Erdős-Rényi algorithm

**condición inicial** Comenzando con N nodos desconectados ( $L = 0$  enlaces)

**paso iterativo** Para cada par de individuos, establezca un vínculo con probabilidad  $p$

# Random Networks

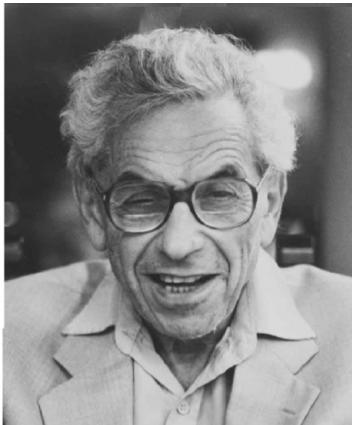
Conectar 1 con 4?

is Random() < p

Si

No

a.

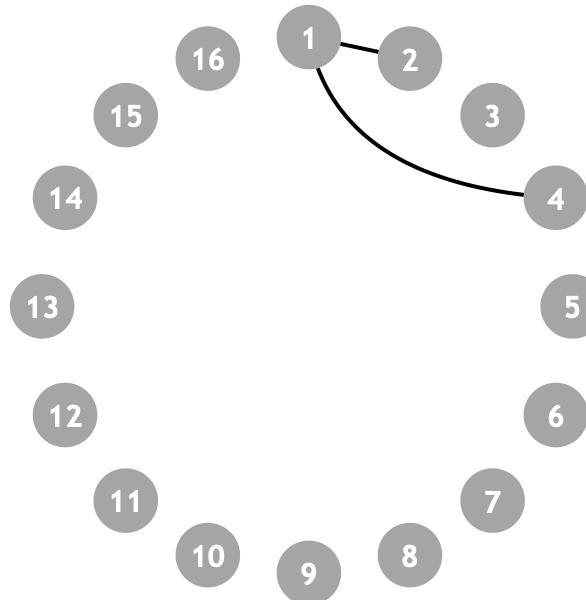


Pál Erdős

b.



Alfréd Rényi



## Erdős-Rényi algorithm

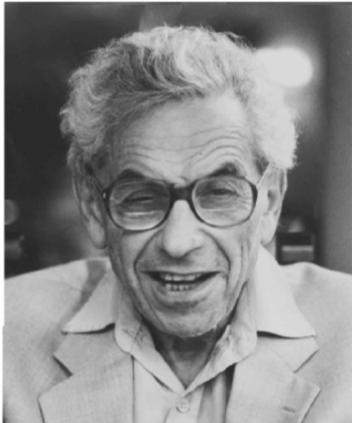
**condición inicial** Comenzando con N nodos desconectados ( $L = 0$  enlaces)

**paso iterativo** Para cada par de individuos, establezca un vínculo con probabilidad p

# Random Networks

Repite para todas las Posibles conexiones de 1

a.

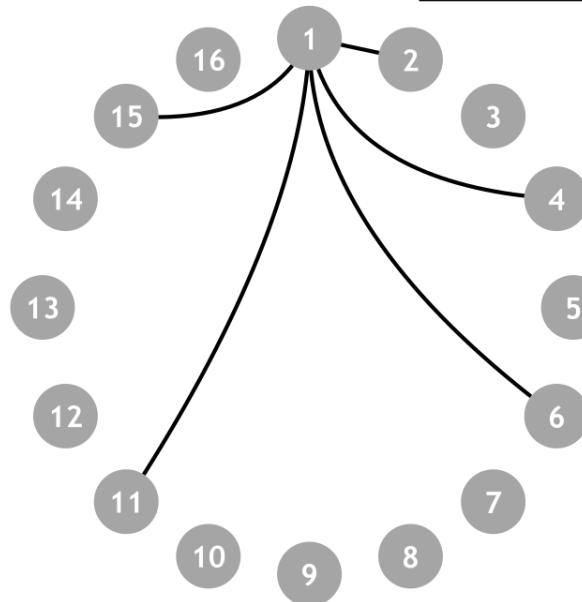


Pál Erdős

b.



Alfréd Rényi



## Erdős-Rényi algorithm

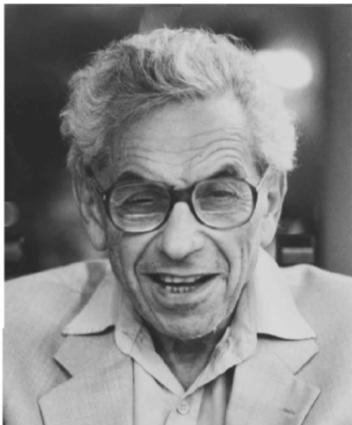
**condición inicial** Comenzando con  $N$  nodos desconectados ( $L = 0$  enlaces)

**paso iterativo** Para cada par de individuos, establezca un vínculo con probabilidad  $p$

# Random Networks

Repite para todos  
Los posibles enlaces

a.

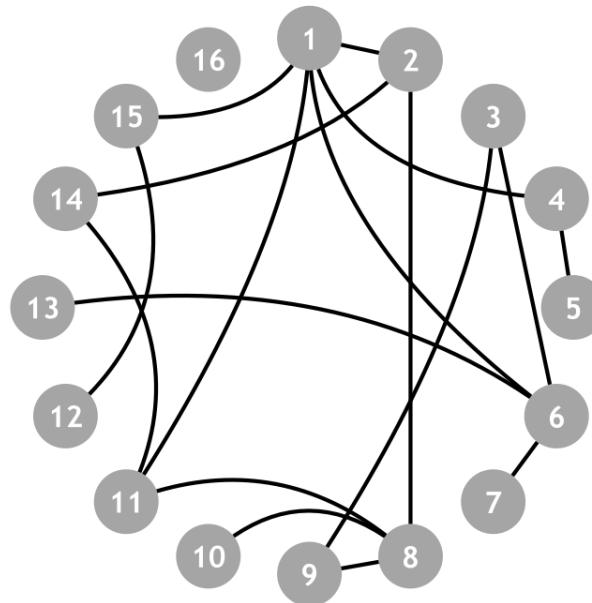


Pál Erdős

b.



Alfréd Rényi



## Erdős-Rényi algorithm

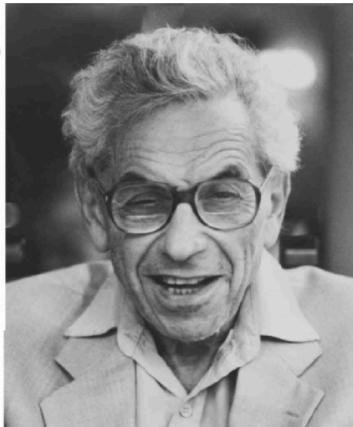
**condición inicial** Comenzando con  $N$  nodos desconectados ( $L = 0$  enlaces)

**paso iterativo** Para cada par de individuos, establezca un vínculo con probabilidad  $p$

El número de enlaces es variable.

# MODELO DE REDES ALEATORIAS

a.



Pál Erdős

b.



Alfréd Rényi

## Erdős-Rényi algorithm

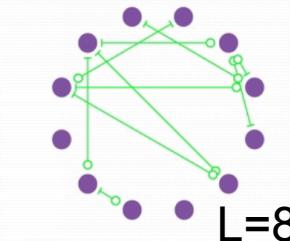
### condición inicial

Comenzando con  $N$  nodos desconectados ( $L = 0$  enlaces)

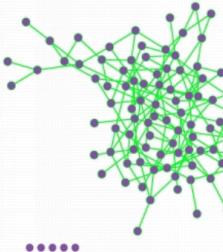
### paso iterativo

Para cada par de individuos, establezca un vínculo con probabilidad  $p$

$$N=12 \quad p=1/6$$



$$N=100 \quad p=0.03$$



$$L=8$$

$$L=10$$

$$L=7$$

Parece una red real, ¿no es así?

# Número de enlaces en una red aleatoria

**P(L)**: la probabilidad de tener exactamente **L** enlaces en una red de **N** nodos y probabilidad **p**:

$$P(L) = \binom{N}{L} p^L (1-p)^{\frac{N(N-1)}{2} - L}$$

El número máximo de enlaces  
en una red de **N** nodos.

Número de formas diferentes en que podemos  
elegir los enlaces **L** entre todos los enlaces  
potenciales.

Distribución binomial...

$$\binom{n}{k} = \frac{n(n-1)\cdots(n-k+1)}{k(k-1)\cdots 1},$$

$$\binom{n}{k} = \frac{n!}{k!(n-k)!},$$

# Tutorial Matemático. | Distribución Binomial: La línea base

$$p_x = \binom{N}{x} p^x (1-p)^{N-x}$$

Dist. Binomial de "x"

Ejemplo:  
N=Enlaces totales potenciales  
x=Enlaces de la red  
p= probabilidad

$$\langle x \rangle = \sum_{x=0}^N x p_x = Np$$

$$\langle x^2 \rangle = p(1-p)N + p^2 N^2$$

$$\sigma_x = \left( \langle x^2 \rangle - \langle x \rangle^2 \right)^{\frac{1}{2}} = [p(1-p)N]^{1/2}$$

# MODELO DE REDES ALEATORIAS

**P(L)**: la probabilidad de tener una red de **L** enlaces exactamente

$$P(L) = \binom{N}{L} p^L (1-p)^{\frac{N(N-1)}{2} - L}$$

- El número promedio de links  $\langle L \rangle$  en un grafo aleatorio

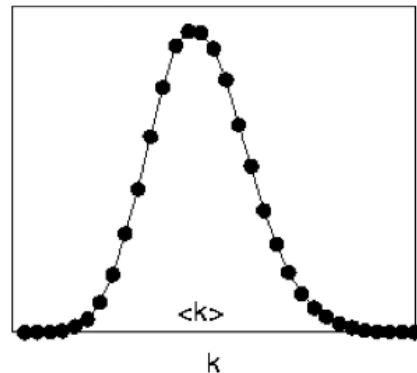
$$\langle L \rangle = \sum_{L=0}^{\frac{N(N-1)}{2}} LP(L) = p \frac{N(N-1)}{2} \longrightarrow \langle k \rangle = 2L/N = p(N-1)$$

- La varianza

$$\sigma^2 = p(1-p) \frac{N(N-1)}{2}$$

# Distribución de grado de una red aleatoria

# DISTRIBUCION DE GRADO DE UNA RED ALEATORIA



Selecciona  $k$  nodos de un conjunto de  $N-1$  nodos

$$P(k) = \binom{N-1}{k} p^k (1-p)^{(N-1)-k}$$

Probabilidad de tener  $k$  enlaces

Probabilidad de perder  $N-1-k$  enlaces

$$\langle k \rangle = p(N-1)$$

$$\sigma_k^2 = p(1-p)(N-1)$$

$$\frac{\sigma_k}{\langle k \rangle} = \left[ \frac{1-p}{p} \frac{1}{(N-1)} \right]^{1/2} \approx \frac{1}{(N-1)^{1/2}}$$

A medida que la red aumenta de tamaño, la distribución se vuelve cada vez más estrecha: estamos cada vez más seguros de que el grado de un nodo se encuentra cerca de  $\langle k \rangle$  (valores homogéneos).

# DISTRIBUCION DE GRADO DE UNA RED ALEATORIA

$$P(k) = \binom{N-1}{k} p^k (1-p)^{(N-1)-k}$$
$$\langle k \rangle = p(N-1)$$
$$p = \frac{\langle k \rangle}{(N-1)}$$

Para  $N$  grandes y  $k$  pequeños, Podemos usar las siguientes aproximaciones ( $N \gg k$ ):

$$\binom{N-1}{k} = \frac{(N-1)!}{k!(N-1-k)!} = \frac{(N-1)(N-1-1)(N-1-2)\dots(N-1-k+1)(N-1-k)!}{k!(N-1-k)!} = \frac{(N-1)^k}{k!}$$

$$\ln[(1-p)^{(N-1)-k}] = (N-1-k) \ln\left(1 - \frac{\langle k \rangle}{N-1}\right) = -(N-1-k) \frac{\langle k \rangle}{N-1} = -\langle k \rangle \left(1 - \frac{k}{N-1}\right) \approx -\langle k \rangle$$

$$(1-p)^{(N-1)-k} = e^{-\langle k \rangle}$$

$$\ln(1+x) = \sum_{n=1}^{\infty} \frac{(-1)^{n+1}}{n} x^n = x - \frac{x^2}{2} + \frac{x^3}{3} - \dots \quad \text{for } |x| \leq 1$$

$$P(k) = \binom{N-1}{k} p^k (1-p)^{(N-1)-k} = \frac{(N-1)^k}{k!} p^k e^{-\langle k \rangle} = \frac{(N-1)^k}{k!} \left(\frac{\langle k \rangle}{N-1}\right)^k e^{-\langle k \rangle} = e^{-\langle k \rangle} \frac{\langle k \rangle^k}{k!}$$

# DISTRIBUCIÓN DE GRADO DE POISSON

$$P(k) = \binom{N-1}{k} p^k (1-p)^{(N-1)-k}$$
$$\langle k \rangle = p(N-1)$$
$$p = \frac{\langle k \rangle}{(N-1)}$$

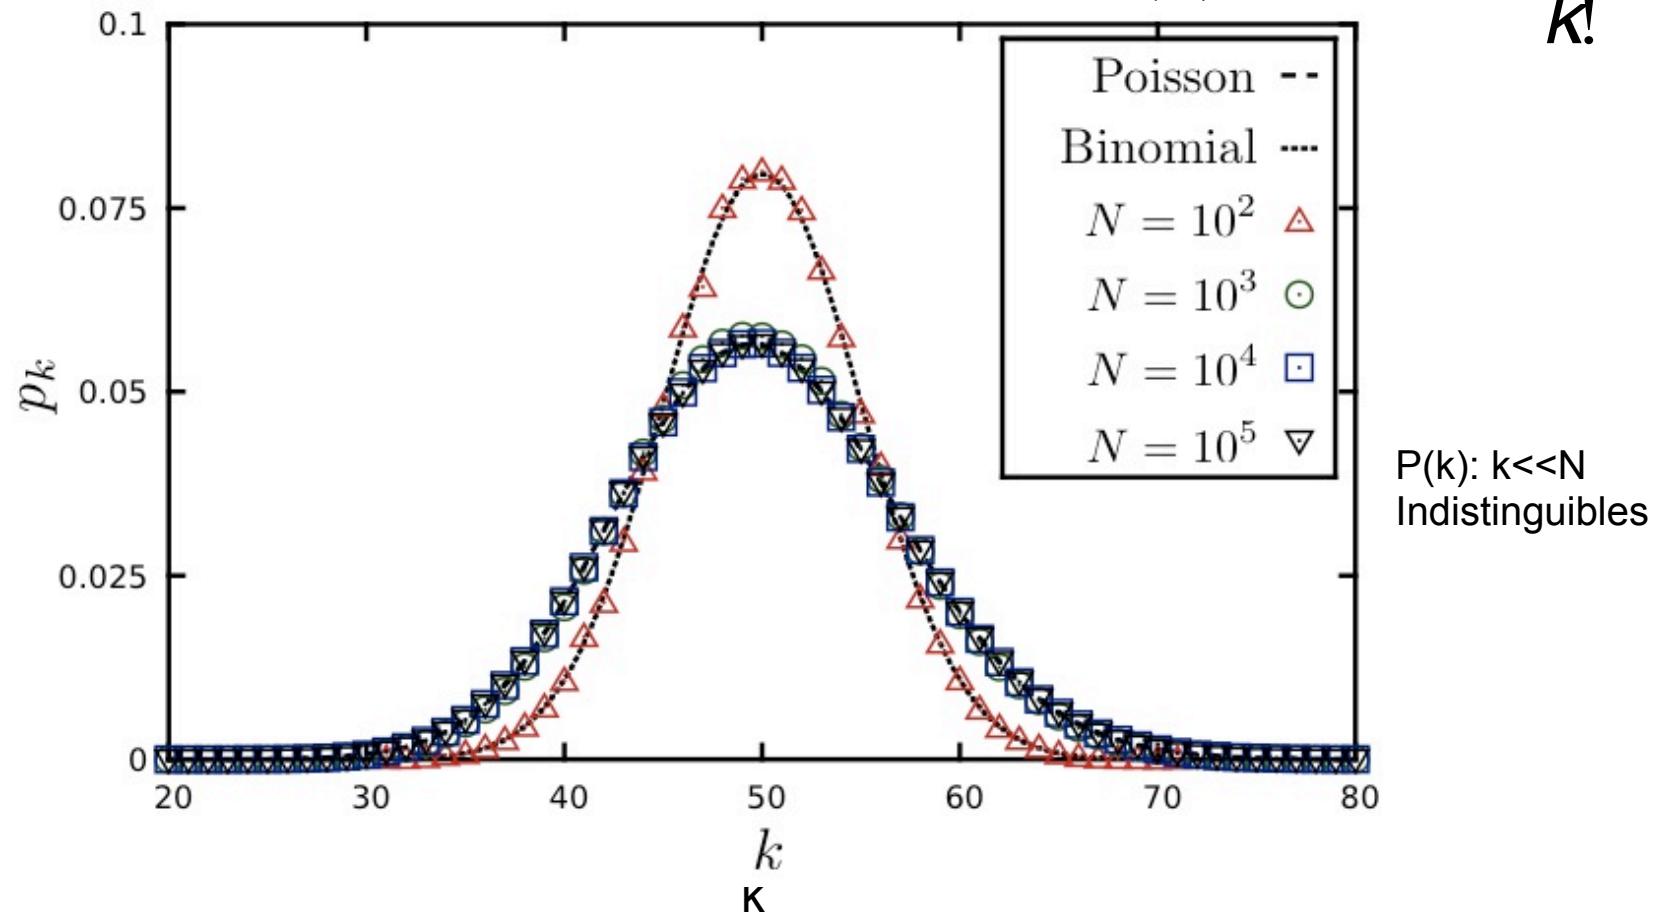
Para  $N$  grandes y  $k$  pequeños, llegamos a la distribución de Poisson:

$$P(k) = e^{-\langle k \rangle} \frac{\langle k \rangle^k}{k!}$$

# DISTRIBUCION DE GRADO DE UNA RED ALEATORIA

$\langle k \rangle = 50$

$$P(k) = e^{-\langle k \rangle} \frac{\langle k \rangle^k}{k!}$$



# DISTRIBUCION DE GRADO DE UNA RED ALEATORIA

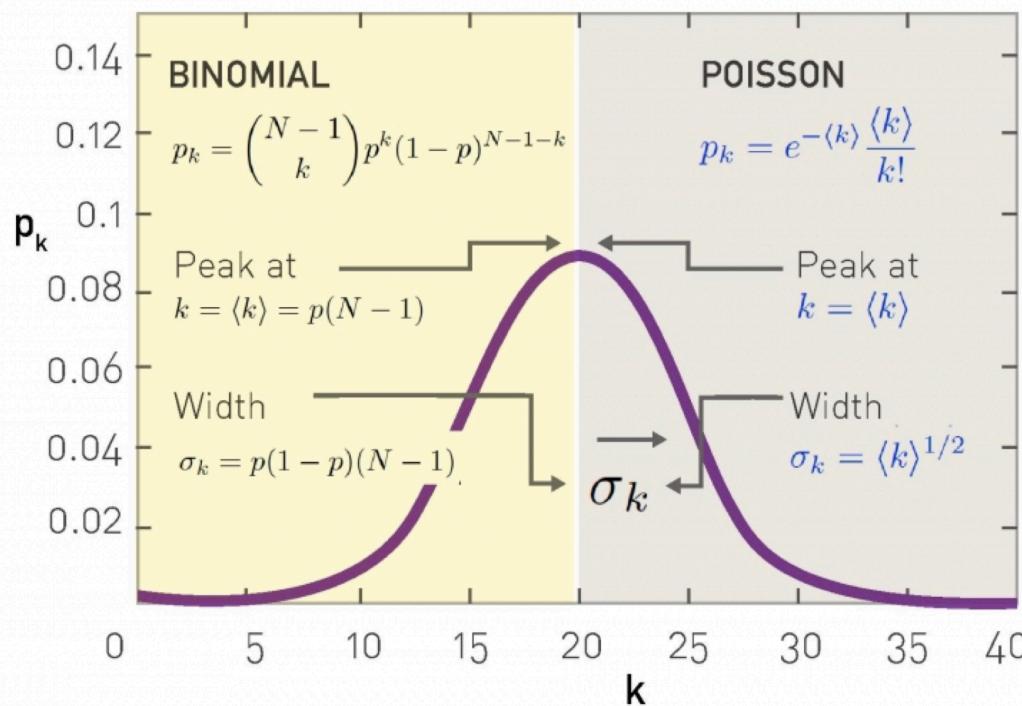
Función de distribución de probabilidad (PDF)

## Resultado exacto

- Distribución Binomial -

## Límite para N grande

- Distribución de Poisson -



**Las redes reales no son Poisson**

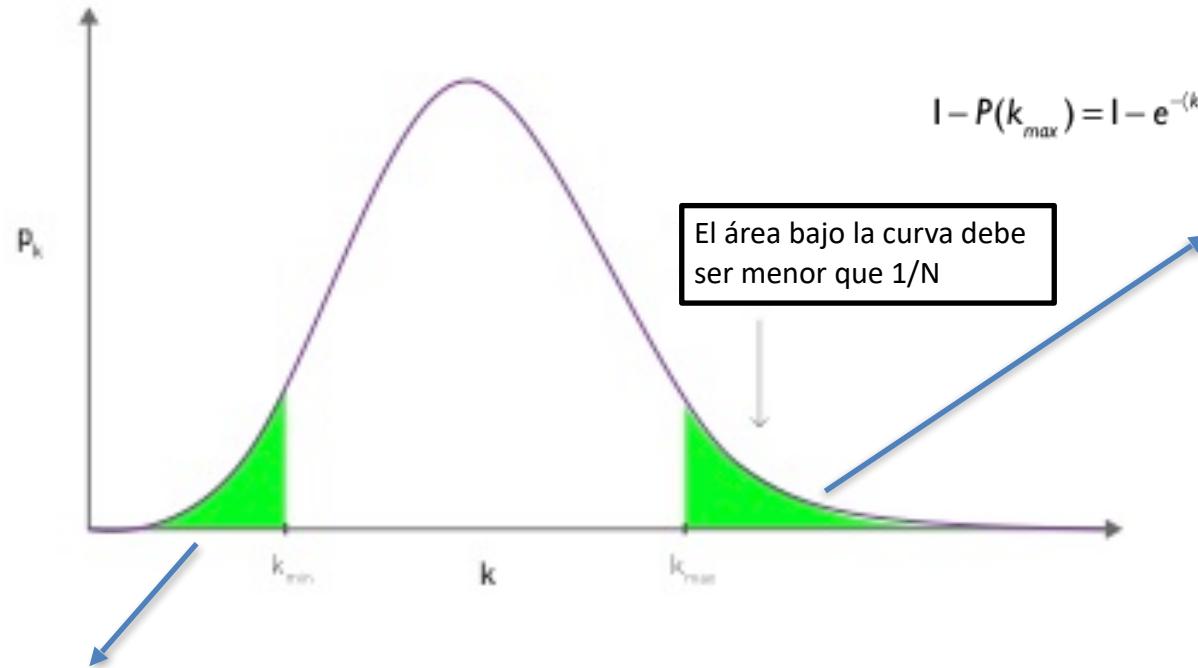
# Grado máximo y mínimo

$$P(k) = e^{-\langle k \rangle} \frac{\langle k \rangle^k}{k!}$$

Ej:  $\langle k \rangle = 1,000$ ,  $N = 10^9$

$$N[1 - P(k_{\max})] \approx 1.$$

$$1 - P(k_{\max}) = 1 - e^{-\langle k \rangle} \sum_{k=0}^{k_{\max}} \frac{\langle k \rangle^k}{k!} = e^{-\langle k \rangle} \sum_{k=k_{\max}+1}^{\infty} \frac{\langle k \rangle^k}{k!} \approx e^{-\langle k \rangle} \frac{\langle k \rangle^{k_{\max}+1}}{(k_{\max}+1)!},$$



$$k_{\max} = 1,185$$

$$NP(k_{\min}) \approx 1.$$

$$R(k_{\min}) = e^{-\langle k \rangle} \sum_{k=0}^{k_{\min}} \frac{\langle k \rangle^k}{k!}.$$

$$k_{\min} = 816$$

$$\langle k \rangle \pm \sigma_k \quad \sigma_k = \langle k \rangle^{1/2}$$

$$\sigma_k = 31.62.$$

# NO HAY “OUTLIERS” EN UNA SOCIEDAD ALEATORIA

**Supongamos que una persona típica conoce aproximadamente 1,000 individuos por su nombre de pila**

$$P(k) = e^{-\langle k \rangle} \frac{\langle k \rangle^k}{k!}$$

→ El individuo más conectado tiene grado  $k_{max} \sim 1,185$

$$1 - P(k_{max}) = 1 - e^{-\langle k \rangle} \sum_{k=0}^{k_{max}} \frac{\langle k \rangle^k}{k!} = e^{-\langle k \rangle} \sum_{k=k_{max}+1}^{\infty} \frac{\langle k \rangle^k}{k!} \approx e^{-\langle k \rangle} \frac{\langle k \rangle^{k_{max}+1}}{(k_{max}+1)!},$$

→ El individuo menos conectado tiene grado  $k_{min} \sim 816$

$$P(k_{min}) = e^{-\langle k \rangle} \sum_{k=0}^{k_{min}} \frac{\langle k \rangle^k}{k!}.$$

**La probabilidad de encontrar un individuo con grado  $k > 2,000$  es  $10^{-27}$ .** Por lo tanto, la posibilidad de encontrar a un individuo con 2,000 conocidos es tan pequeña que tales nodos son virtualmente inexistentes en una sociedad aleatoria.

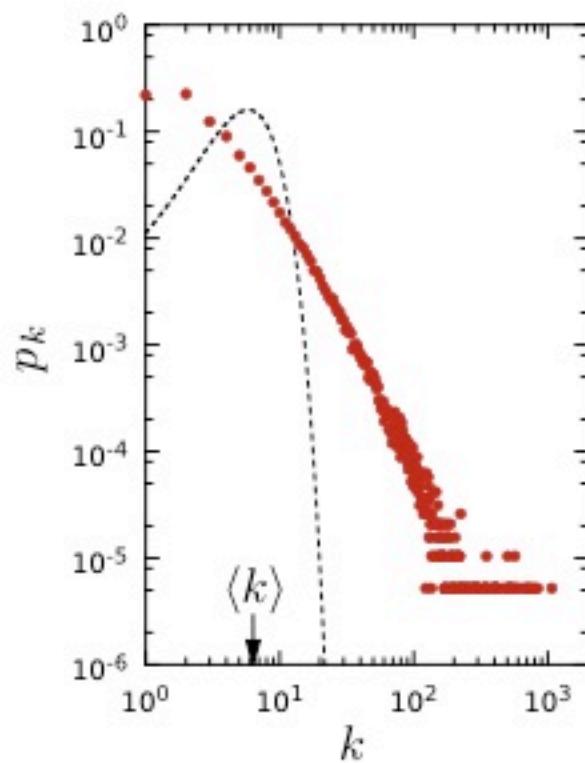
→ una sociedad aleatoria consistiría principalmente en individuos promedio, con todos con aproximadamente el mismo número de amigos.

→ Carecería de valores atípicos, individuos que son muy populares o solitarios.

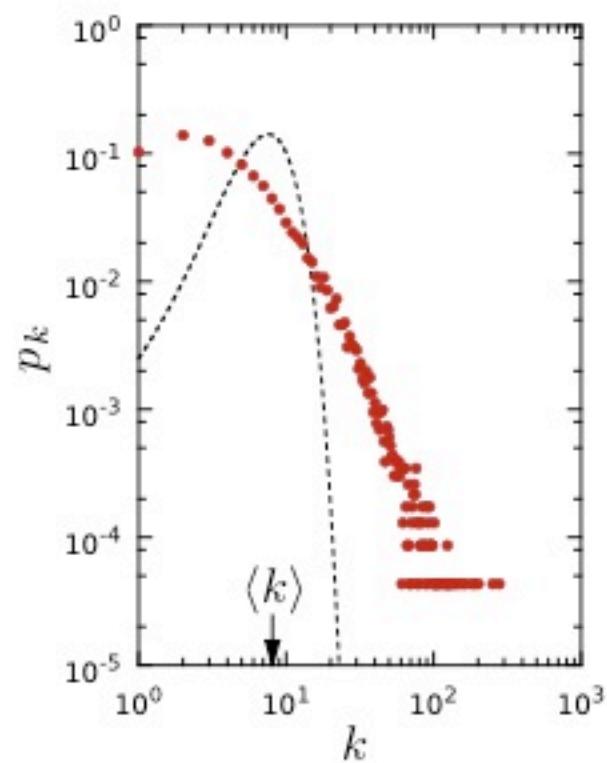
# ENFRENTANDO LA REALIDAD: Distribución en grado de redes reales.

$$P(k) = e^{-\langle k \rangle} \frac{\langle k \rangle^k}{k!}$$

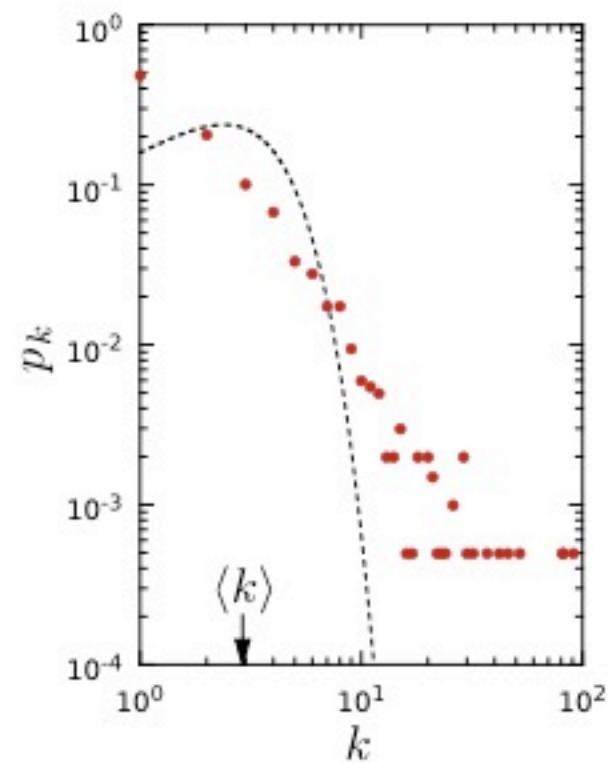
Internet



Science Collaboration



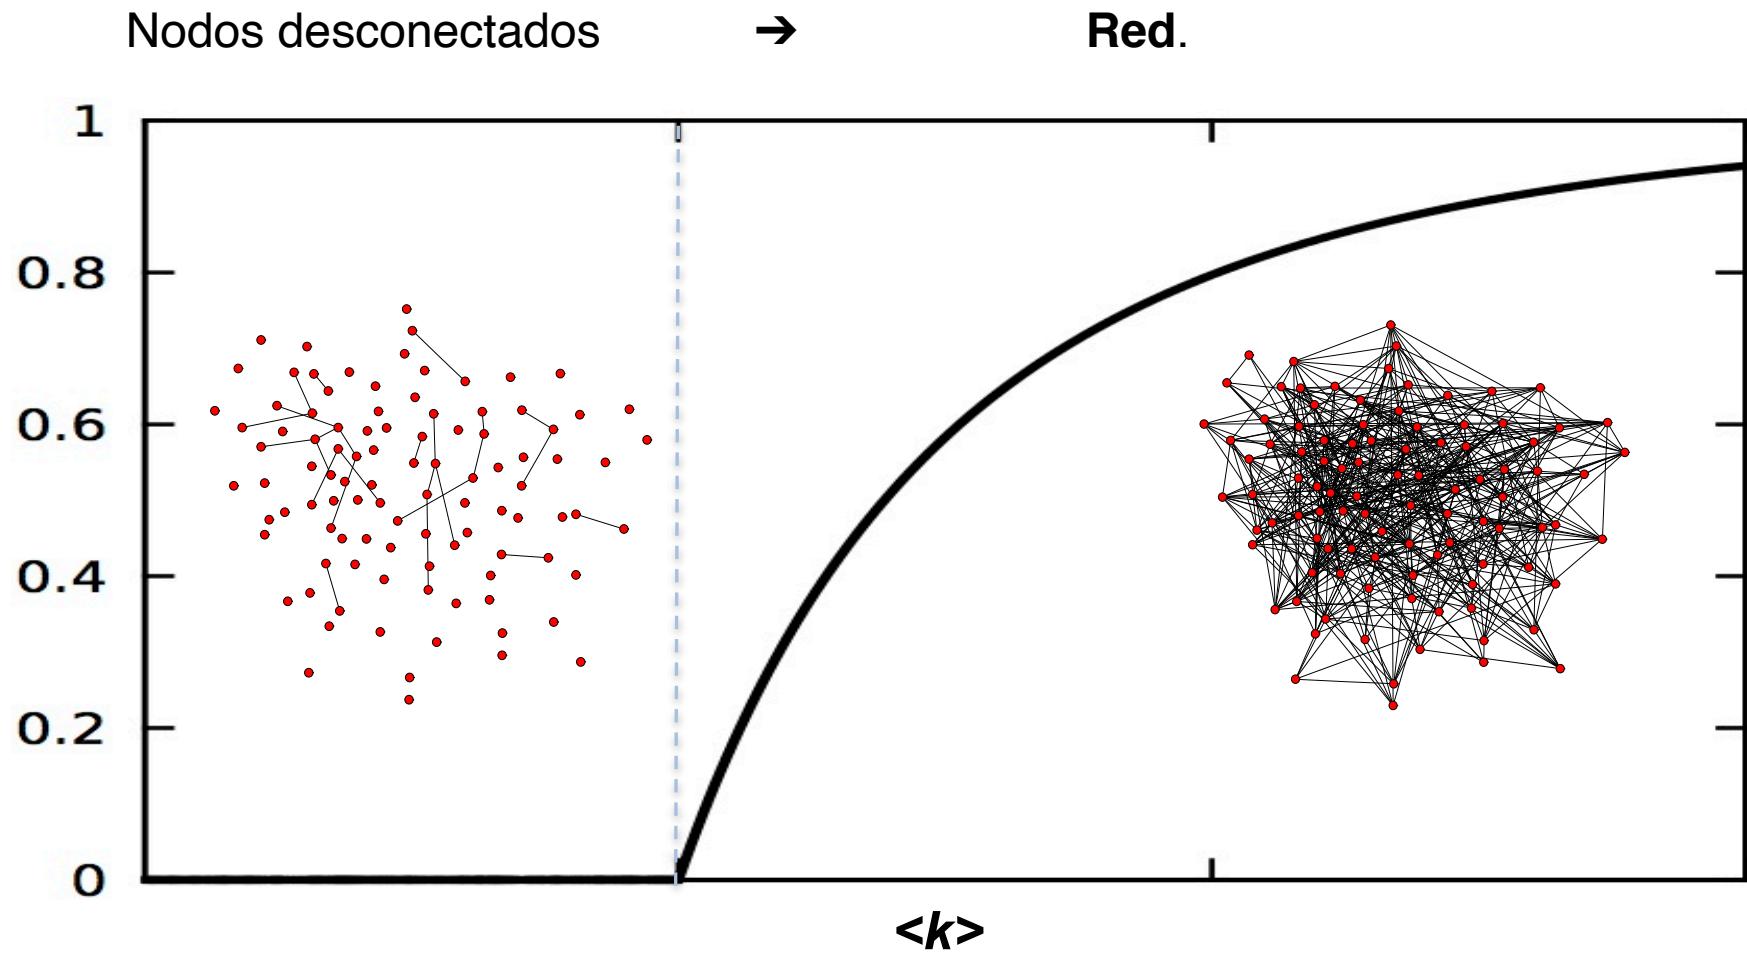
Protein Interactions



# La evolución de una red aleatoria.



# Evolución de una red aleatoria



# DISTRIBUCION DEL TAMAÑO DEL GRUPO (CLUSTER)

Probabilidad de que un nodo seleccionado al azar pertenezca a un grupo de tamaño  $s$ :

$$p(s) = \frac{e^{-\langle k \rangle s} (\langle k \rangle s)^{\langle k \rangle - 1}}{s}$$

$$\langle k \rangle^{\langle k \rangle - 1} = \exp[(s-1)\ln\langle k \rangle]$$

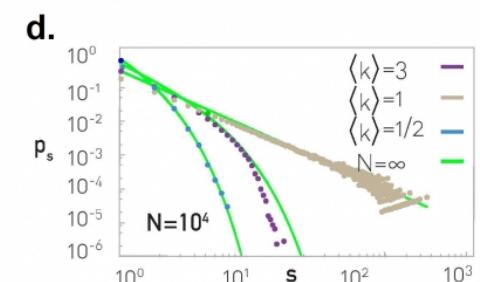
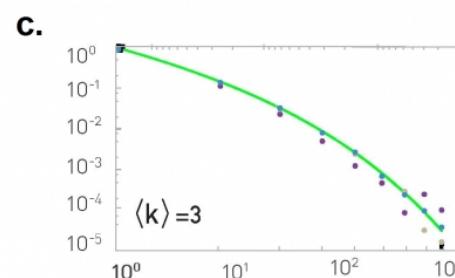
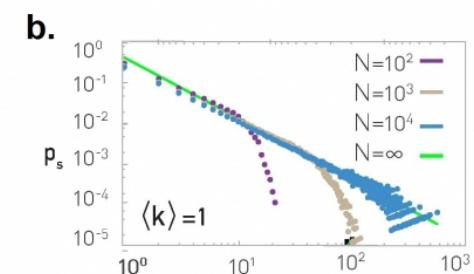
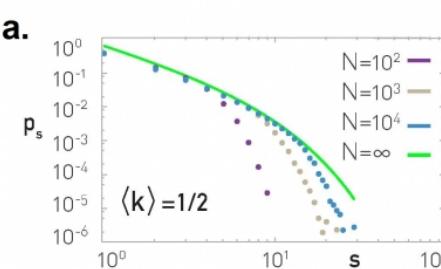
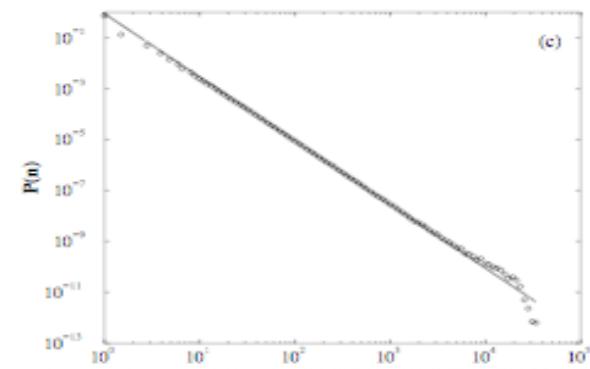
$$p(s) = \frac{s^{\langle k \rangle - 1}}{s} e^{-\langle k \rangle s + (s-1)\ln\langle k \rangle}$$

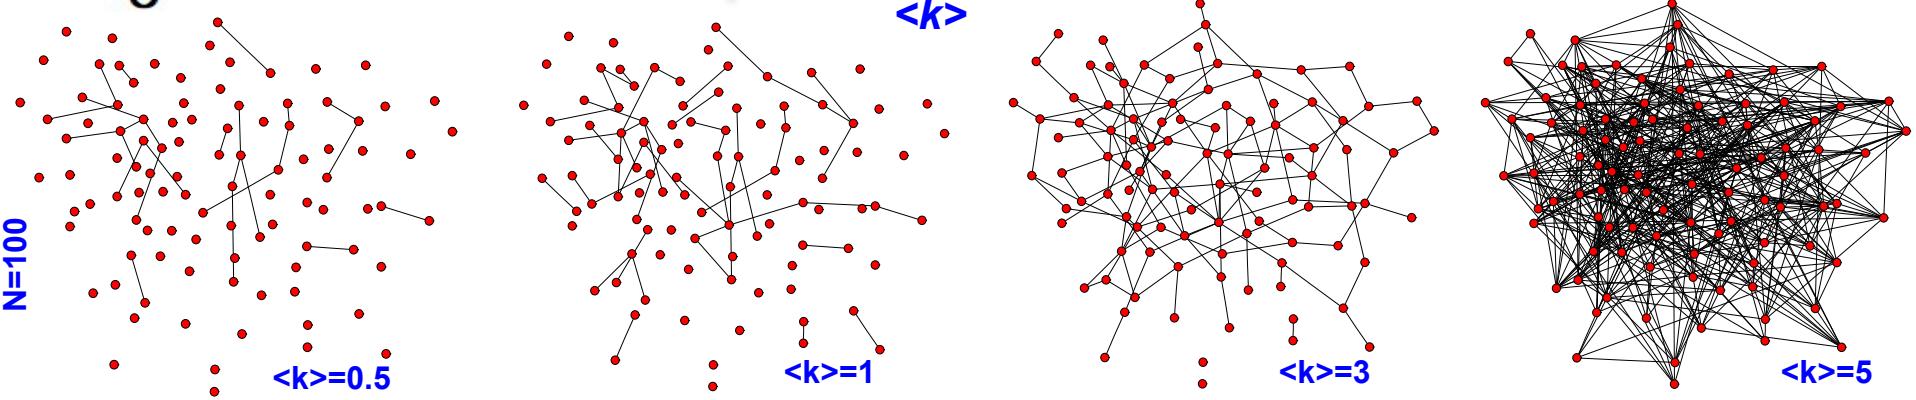
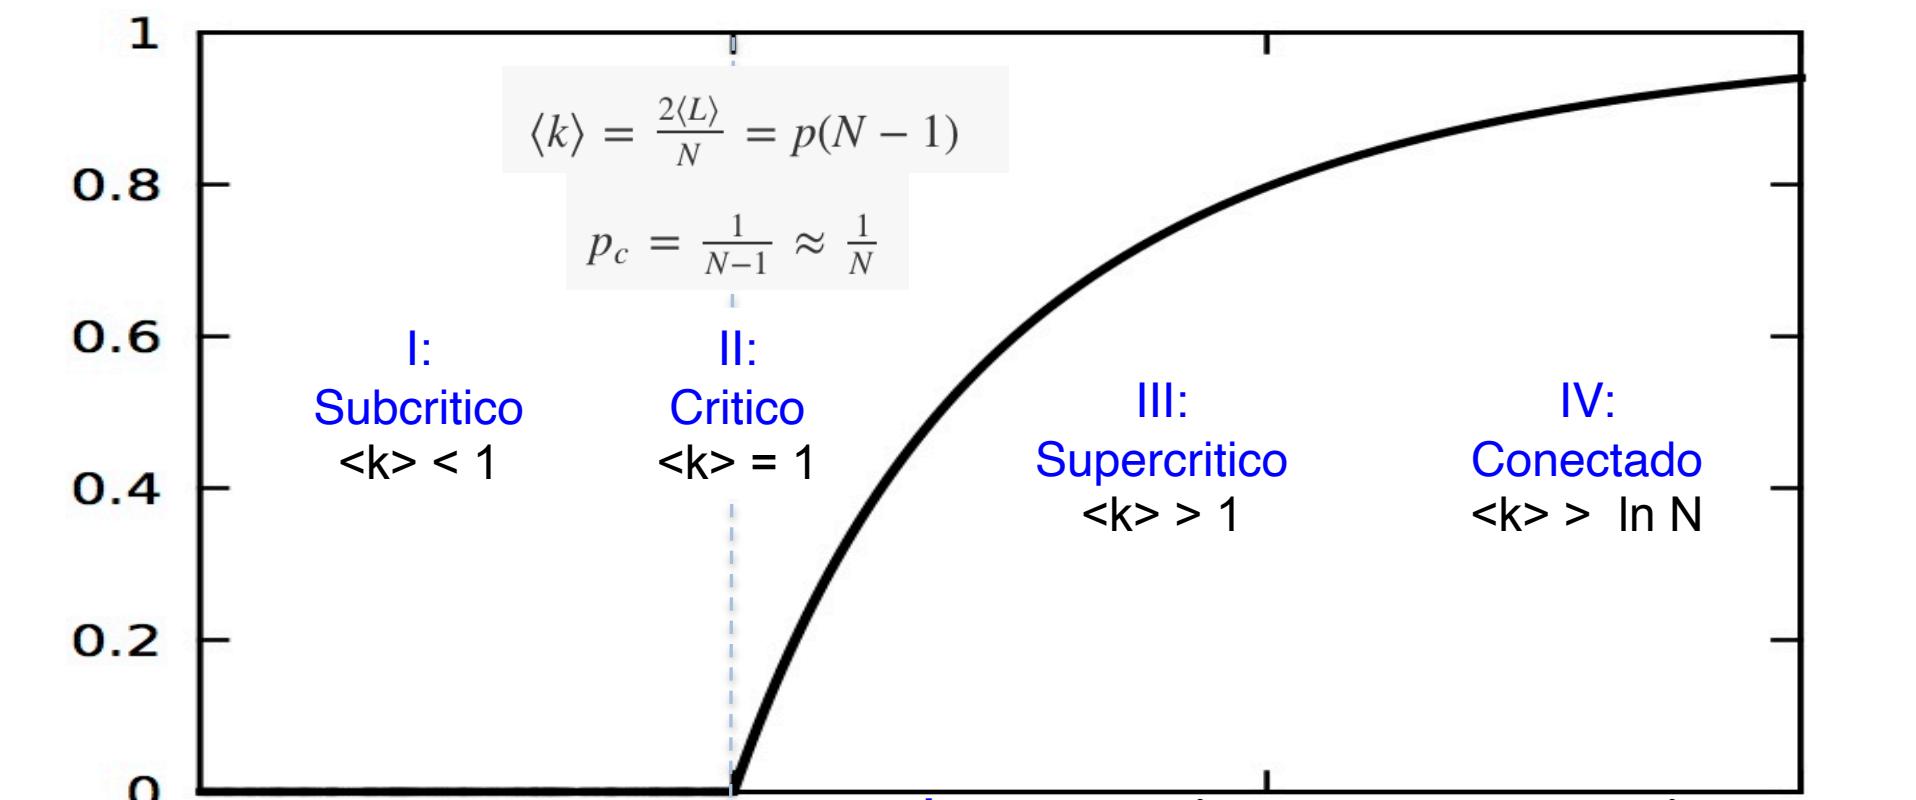
$$s = \sqrt{2\pi} \left(\frac{s}{e}\right)^{\langle k \rangle}$$

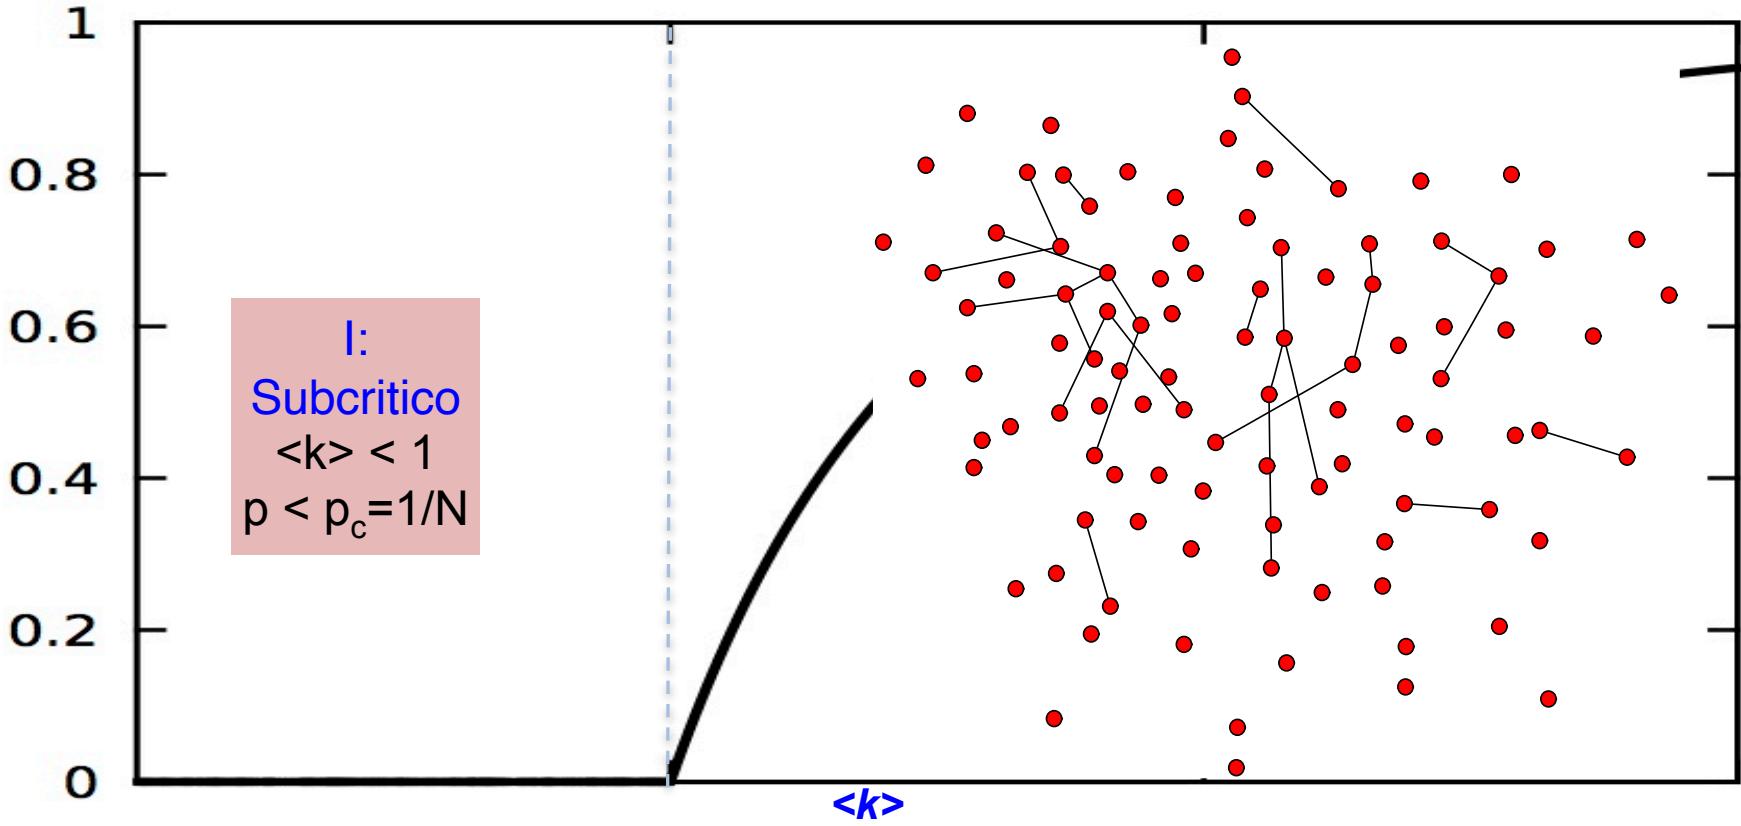
$$p(s) \sim s^{-3/2} e^{-(\langle k \rangle - 1)s + (s-1)\ln\langle k \rangle}$$

At the critical point  $\langle k \rangle = 1$

$$p(s) \sim s^{-3/2}$$



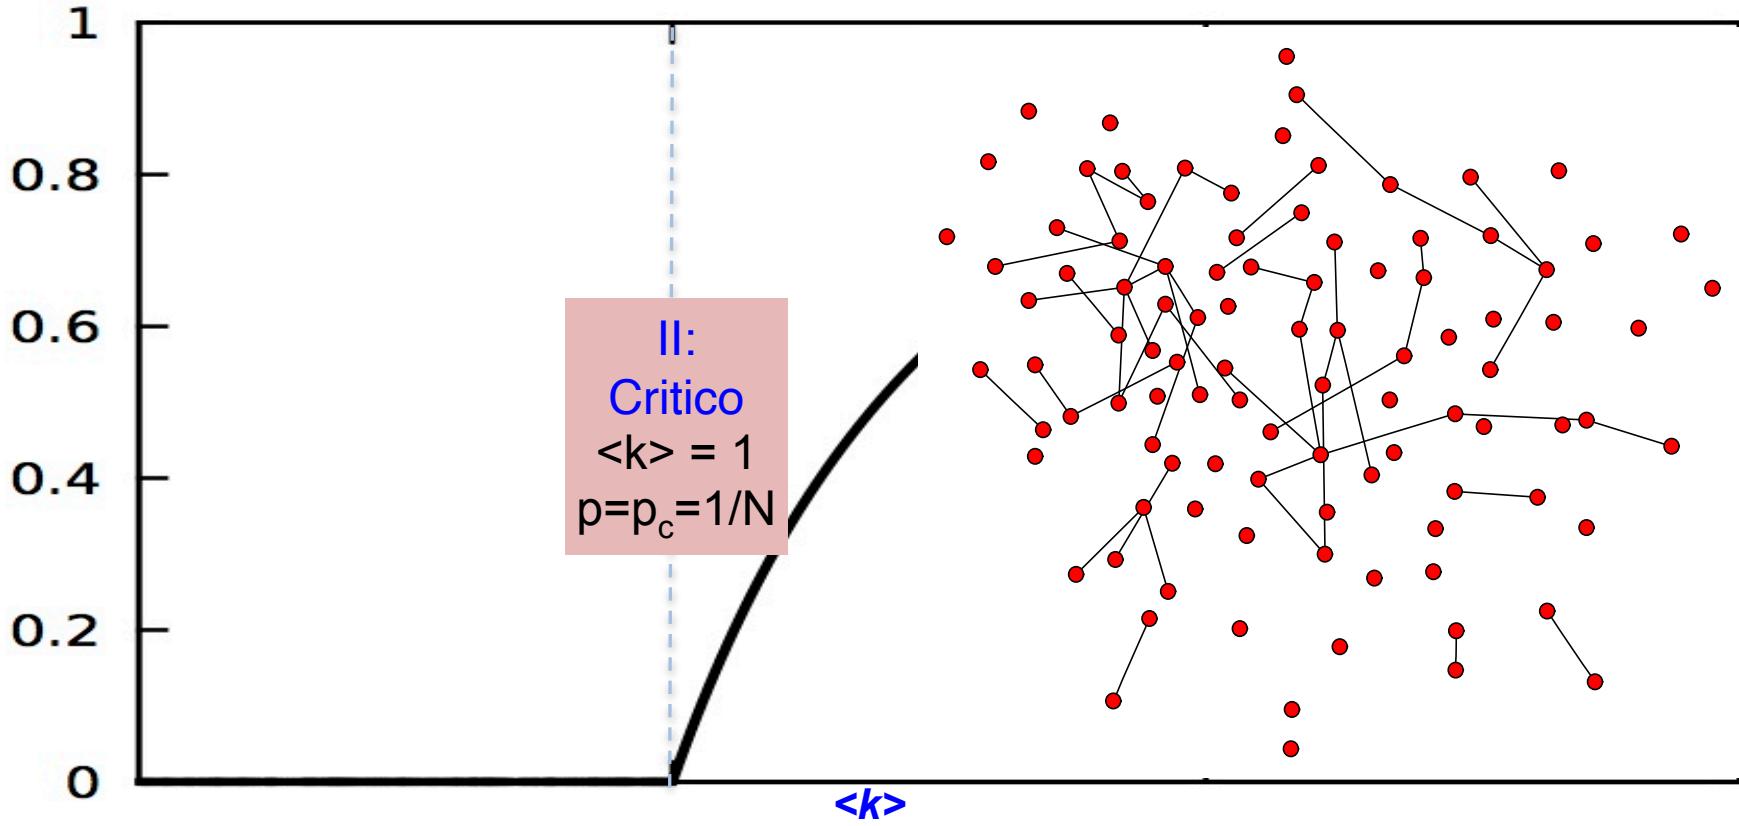




No hay componente gigante

$$p(s) \sim s^{-3/2} e^{-(\langle k \rangle - 1)s + (s-1)\ln \langle k \rangle}$$

N-L clusters aislados, la distribución del tamaño del cluster es exponencial  
El cluster mas grande es un árbol, su tamaño es  $\sim \ln N$



Una sola componente gigante:  $N_G \sim N^{2/3}$

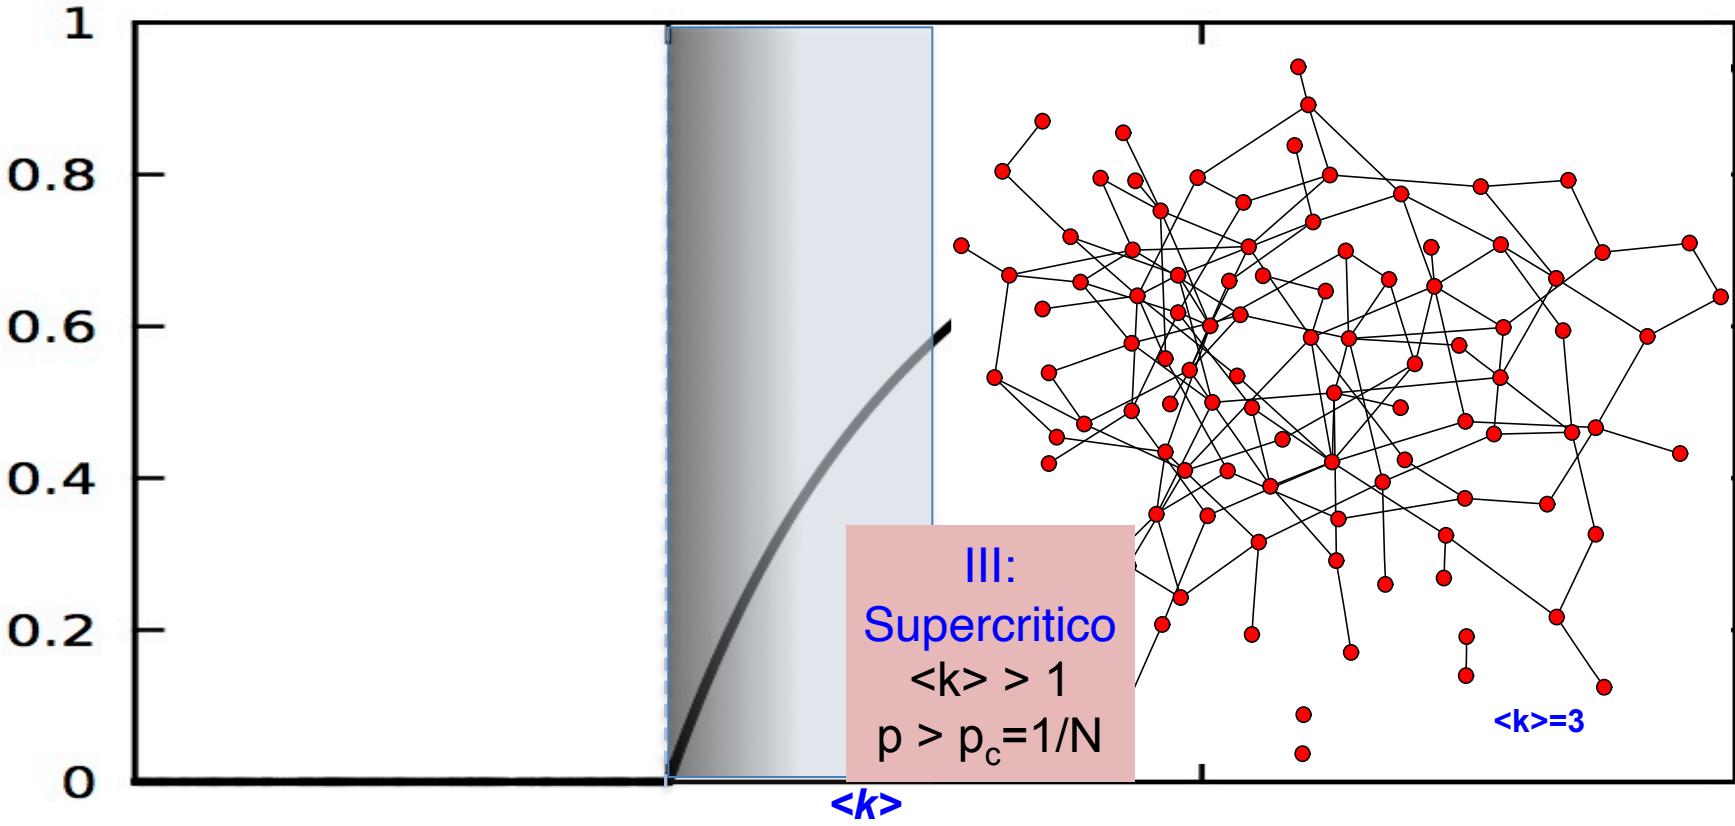
→ Contiene una decreciente fracción de todos los nodos,  $N_G/N \sim N^{-1/3}$

→ Componentes pequeños son árboles, GC tiene loops

Distribución del tamaño de cluster:  $p(s) \sim s^{-3/2}$

(Power-law/ley de potencia)

Un salto en el tamaño del cluster:  
 $N=1,000 \rightarrow \square \square \ln N \sim 6.9; N^{2/3} \sim 95$   
 $N=7 \cdot 10^9 \rightarrow \square \square \ln N \sim 22; N^{2/3} \sim 3,659,250$

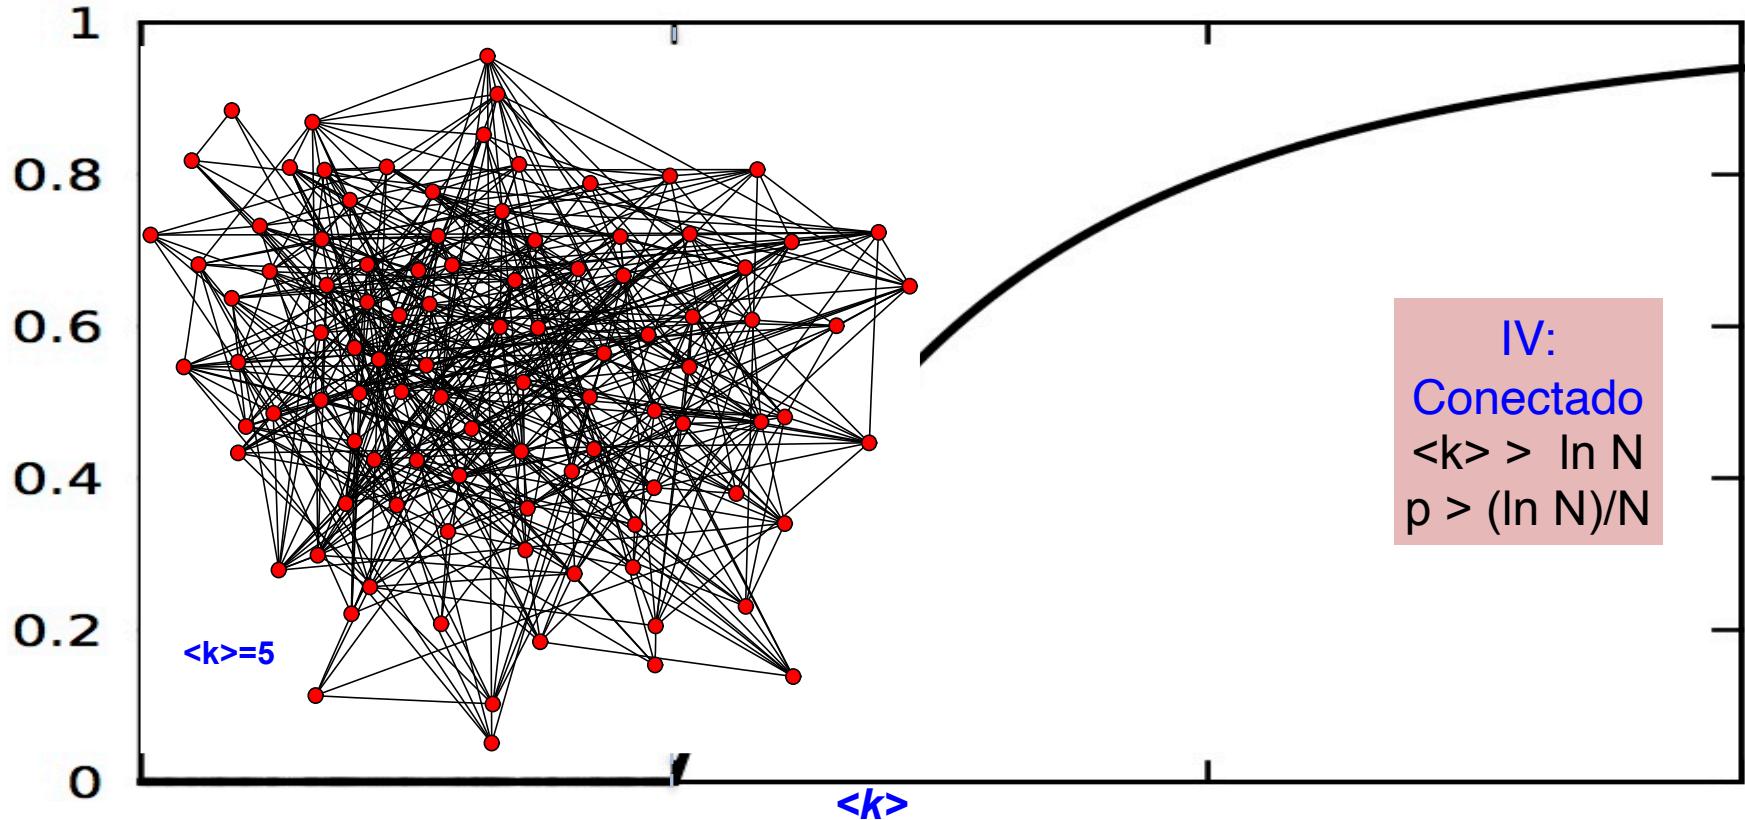


Una sola componente gigante:  $N_G \sim (p - p_c)N$

→ GC tiene loops.

Distribución de tamaños de clusters: exponencial

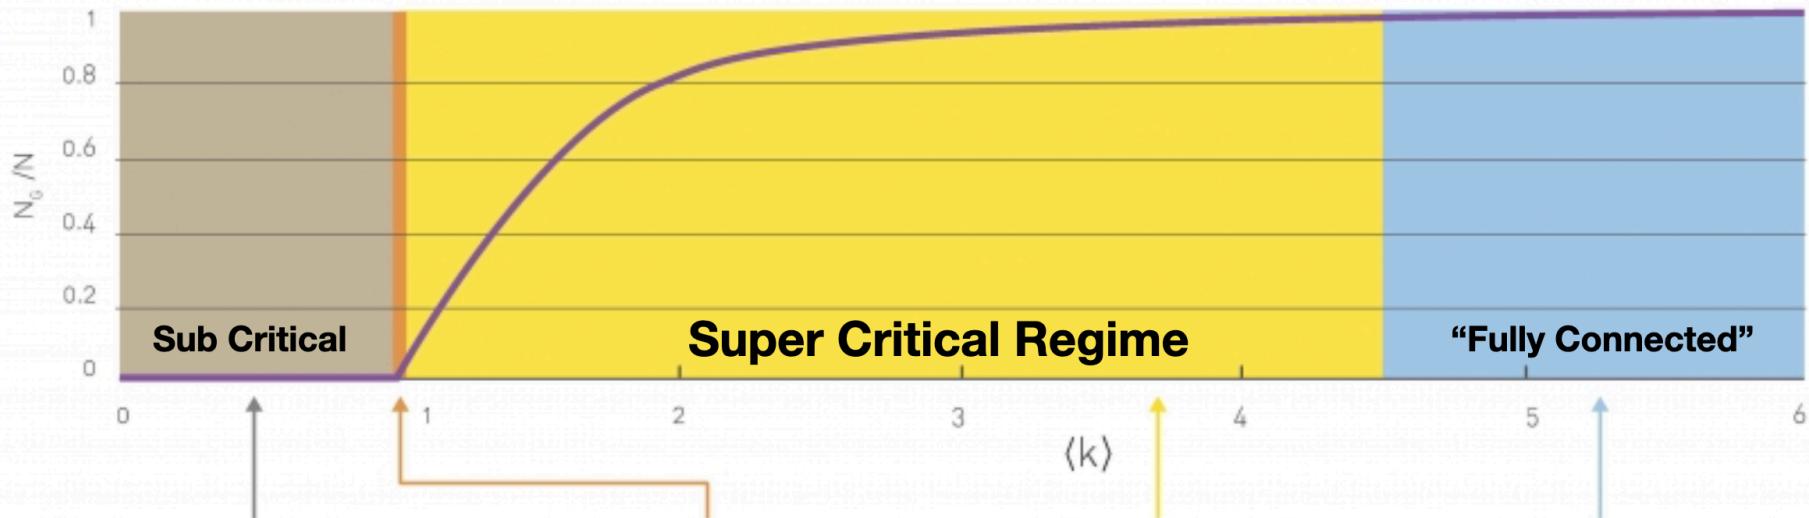
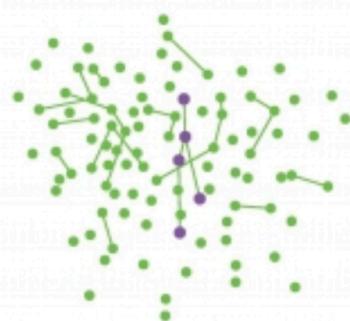
$$p(s) \sim s^{-3/2} e^{-(\langle k \rangle - 1)s + (s-1)\ln \langle k \rangle}$$



Solo un cluster:  $N_G=N$

→ GC es densa.

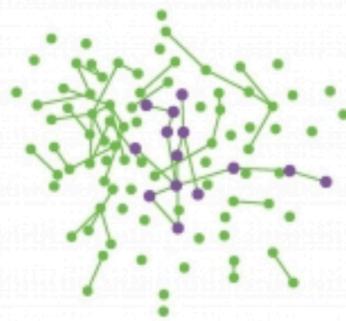
Distribución de tamaño de clusters: Ninguna

**a.****b.**

$$\langle k \rangle < 1$$

#### (b) Subcritical Regime

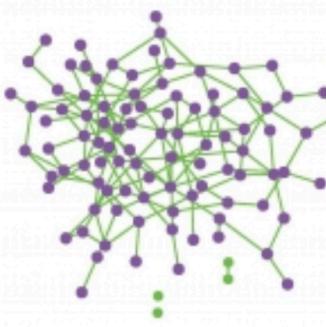
- \* No giant component
- \* Cluster size distribution:  $p_i \sim s^{-3/2} e^{-si}$
- \* Size of the largest cluster:  $N_G \sim \ln N$
- \* The clusters are trees

**c.**

$$\langle k \rangle = 1$$

#### (c) Critical Point

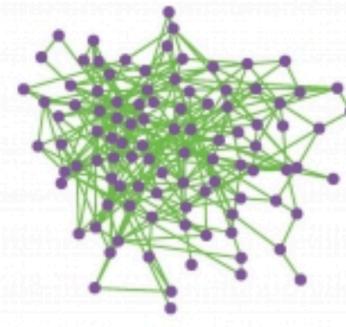
- \* No giant component
- \* Cluster size distribution:  $p_i \sim s^{-3/2}$
- \* Size of the largest cluster:  $N_G \sim N^{1/2}$
- \* The clusters may contain loops

**d.**

$$\langle k \rangle > 1$$

#### (d) Supercritical Regime

- \* Single giant component
- \* Cluster size distribution:  $p_i \sim s^{-3/2} e^{-si}$
- \* Size of the giant component:  $N_G \sim (p - p_c)N$
- \* The small clusters are trees
- \* Giant component has loops

**e.**

$$\langle k \rangle \geq \ln N$$

#### (e) Connected Regime

- \* Single giant component
- \* No isolated nodes or clusters
- \* Size of the giant component:  $N_G = N$
- \* Giant component has loops

# Evolución de una red aleatoria

Nodos desconectados

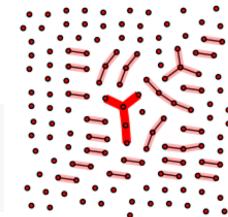


Red.

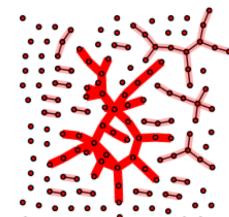
$$\langle k \rangle = \frac{2\langle L \rangle}{N} = p(N - 1)$$

$$p_c = \frac{1}{N-1} \approx \frac{1}{N}$$

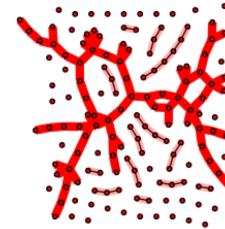
$p = 0.003$



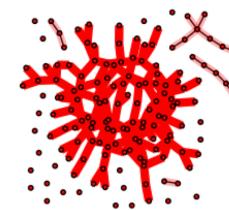
$p = 0.006$



$p = 0.008$



$p = 0.015$



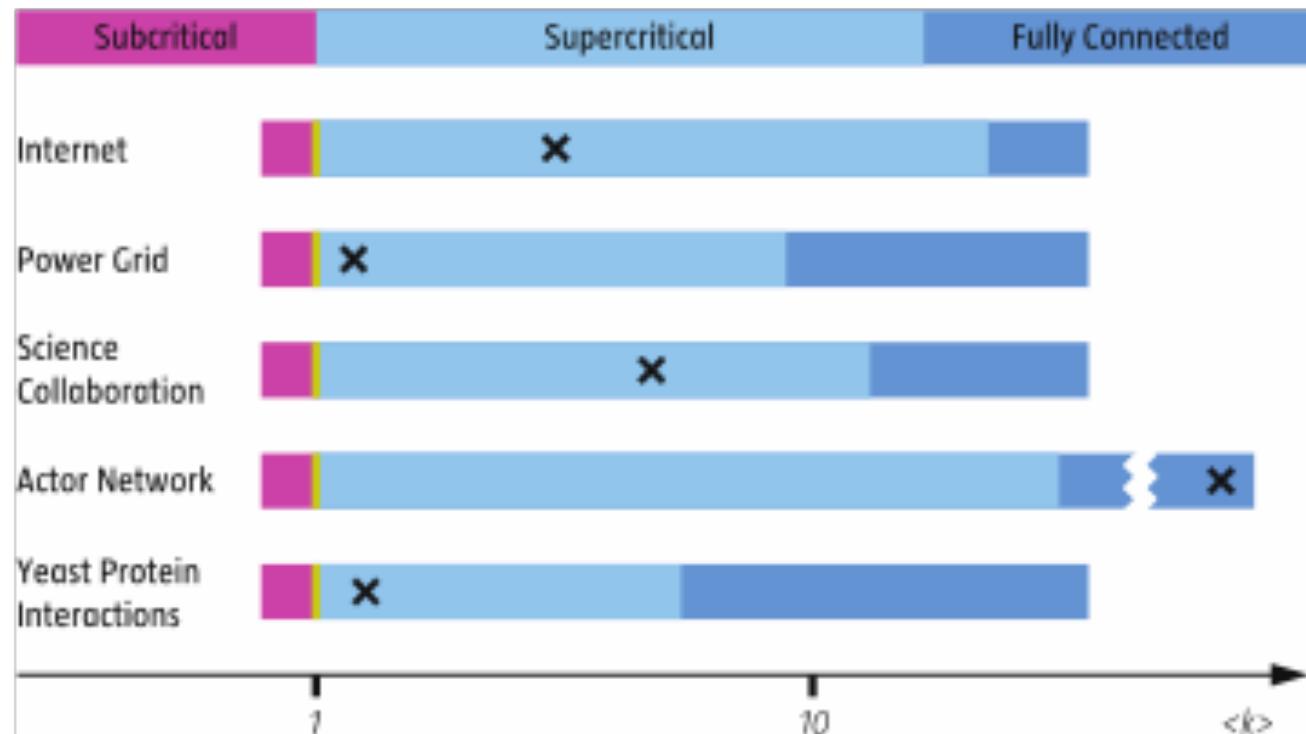
$\langle k_c \rangle = 1/N * (N-1) = 1$ , para  $N$  grande  
(Erdos y Renyi, 1959)

El hecho de que al menos un enlace por nodo sea **necesario** para tener un componente gigante no es inesperado. De hecho, para que exista un componente gigante, cada uno de sus nodos debe estar vinculado al menos a otro nodo.

Es algo inesperado, sin embargo, que un enlace es **suficiente** para el surgimiento de un componente gigante.

Es igualmente interesante que la aparición del componente gigante no sea gradual, pero sigue lo que los físicos llaman una **transición de fase** de segundo orden en  $\langle k \rangle = 1$ .

Las redes reales son supercríticas.



Network	N	L	$\langle k \rangle$	$\ln N$
Internet	192,244	609,066	6.34	12.17
Power Grid	4,941	6,594	2.67	8.51
Science Collaboration	23,133	94,437	8.08	10.05
Actor Network	702,388	29,397,908	83.71	13.46
Protein Interactions	2,018	2,930	2.90	7.61

Red conectada  
 $\langle k \rangle > \ln N$

## Preguntas básicas

- Qué representa la distribución de grado en una red y por qué es un concepto importante en análisis de redes?
- De qué manera se relaciona el concepto de centralidad de grado con distribución de grado de una red?
- Explica el concepto de una red aleatoria y cómo difiere de una red real.
- Considera una red aleatoria de  $N = 2,000$ . Cuál es el numero estimado de links a una probabilidad  $p = 10^{-3}$ ? Y qué pasa con esa red si agregas el número de nodos a  $N = 3,000$ ? Encuentra la probabilidad  $p_c$  de manera que la red se encuentre en su punto critico.